

Machine Learning (1)

Hunsik Shin

Department of Industrial and Data Engineering

{hunsik.shin}@hongik.ac.kr

Machine Learning Basics

Machine learning (기계학습)

A set of methods that can automatically detect patterns in data, and then use the uncovered patterns to predict future data, or to perform other kinds of decision making under uncertainty

"Machine Learning: A Probabilistic Perspective" by Kevin P. Murphy

Supervised learning (지도학습)

- Machine learning task of inferring a function from **labeled** training data
- 정답을 맞히는데 필요한 정보와 정답 모두 있는 데이터를 학습

Unsupervised learning (비지도학습)

- Machine learning algorithm used to draw inferences from **unlabeled** training data
- 관측치의 특성 정보를 담고 있는 데이터에 적용, 데이터에 존재하는 패턴 혹은 인사이트를 찾음

Reinforcement learning (강화학습)

- concerned with how software agents

Machine Learning Basics

Supervised Learning (지도학습)

Machine learning task of inferring a function from **labeled** training data
정답을 맞히는데 필요한 정보와 정답 모두 있는 데이터를 학습

➤ Example : Classifying dogs and cats




<Example images of dogs and cats>

Machine Learning Basics

Supervised Learning (지도학습)

Machine learning task of inferring a function from **labeled** training data
정답을 맞히는데 필요한 정보와 정답 모두 있는 데이터를 학습

- Example : Classifying dogs and cats
- Objective




Machine Learning Basics

Supervised Learning (지도학습)

Machine learning task of inferring a function from **labeled** training data

정답을 맞히는데 필요한 정보와 정답 모두 있는 데이터를 학습

- Example : Classifying dogs and cats
- Data format




Machine Learning Basics

Supervised Learning (지도학습)


Machine learning task of inferring a function from **labeled** training data

정답을 맞히는데 필요한 정보와 정답 모두 있는 데이터를 학습

- Example : Classifying dogs and cats
- Data format



< Representation of an image as a matrix* >



< Color image representation in the RGB color domain** >

* <https://towardsdatascience.com/computer-vision-image-formation-and-representation-a63e348e16b4>


Machine Learning Basics

Supervised Learning (지도학습)

Machine learning task of inferring a function from **labeled** training data

정답을 맞히는데 필요한 정보와 정답 모두 있는 데이터를 학습

- Example : Classifying dogs and cats
- Data format




Machine Learning Basics

Supervised Learning (지도학습)

Machine learning task of inferring a function from **labeled** training data
정답을 맞히는데 필요한 정보와 정답 모두 있는 데이터를 학습

- **Example : Classifying dogs and cats**
- **Learning procedure**
 - **Predictive modeling**
 - Split the data into *train set* and *test set*
 - Fit the model to *train set* & Test the model to *train set* and *test set*




Machine Learning Basics

Supervised Learning (지도학습)

Machine learning task of inferring a function from **labeled** training data
정답을 맞히는데 필요한 정보와 정답 모두 있는 데이터를 학습

- **Example : Classifying dogs and cats**
- **Learning procedure**
 - **Predictive modeling**
 - Split the data into *train set* and *test set*
 - Fit the model to *train set* & Test the model to *train set* and *test set*



Machine Learning Basics

Supervised Learning (지도학습)

Machine learning task of inferring a function from **labeled** training data


정답을 맞히는데 필요한 정보와 정답 모두 있는 데이터를 학습

➤ Example : Classifying dogs and cats

➤ Learning procedure

- Predictive modeling

- Split the data into *train set* and *test set*
- Fit the model to *train set* & Test the model to *train set* and *test set*




Machine Learning Basics

Supervised Learning (지도학습)

Machine learning task of inferring a function from **labeled** training data

정답을 맞히는데 필요한 정보와 정답 모두 있는 데이터를 학습

- **Example : Classifying dogs and cats**
- **Learning procedure**



Machine Learning Basics

Supervised Learning (지도학습) For Text Mining

문서(=Document)를 수치형 벡터로 표현(e.g. Bag-of-Words, Doc2Vec 등)하고 문서마다 Label 정보(e.g. Spam/Non-Spam)를 활용하여 분류 모델을 학습 및 추론



Machine Learning Basics

Supervised Learning (지도 학습)

Classification(분류): Output Y 가 이산형(discrete)이거나 범주형(categorical)일 때 지도 학습 task

- 제품의 품질 분류 : $Y = \{ \text{불량, 정상} \}$
- 스팸 메일 분류 : $Y = \{ \text{정상 메일, 스팸 메일} \}$

Regression(회귀)/Prediction(예측): Output Y 가 연속형(continuous)이거나 실수(real number)일 때 지도 학습 task


- 내일 KOSPI 200 증가(= Y) 예측
- 강수량(= Y) 예측
- 5일 뒤의 전력 사용량 예측

Machine Learning Basics

Supervised Learning (지도 학습)

Classification(분류): Output Y가 이산형(discrete)이거나 범주형(categorical)일 때 지도 학습 task


Regression(회귀)/Prediction(예측): Output Y가 연속형(continuous)이거나 실수(real number)일 때 지도 학습 task



Machine Learning Basics

Supervised Learning (지도학습)


Classification(분류): Output Y가 이산형(discrete)이거나 범주형(categorical)일 때 지도 학습 task



Machine Learning Basics

Supervised Learning (지도 학습)

Regression(회귀)/Prediction(예측): Output Y가 연속형(continuous)이거나 실수(real number)일 때 지도 학습 task



Learning algorithm

Find a regression line or a regression model based on given "training set".

Model or Regressor

$$Y = aX_1 + b$$

Prediction: Predict its output value

A new point is observed.
What is the output value of this point?



Machine Learning Basics

기계학습 모델 학습의 의미

분류 모델의 성능은 정확도(=accuracy)를 기준으로 측정 → 높은 정확도를 갖는 모델이 좋은 성능을 가짐


- 모델 학습 목표 = 높은 성능
- 모델의 학습 과정 = 모델의 성능이 높도록 모델을 구성하는 가중치(=weight)를 정하는 과정
e.g. $y = a * X_1 + b * X_2 + c * X_3$ 모델일 때, 주어진 데이터를 기반으로 성능이 높을 수 있는 a, b, c 값을 찾는 것
- 성능의 반대 개념은 손실(=loss), 오류(=cost) → 높은 성능 = 낮은 손실 = 낮은 오류
- 모델을 학습할 땐, **성능을 최대화**(=maximization)하거나 **손실을 최소화**(=minimization)하는 가중치 계산
→ 대부분의 경우, 손실을 최소화하는 방법을 사용

회귀분석(Regression Analysis)


- 1885년 영국 F. Galton의 1078쌍 부자간의 키 관계 분석이 시초: 회귀 [regression, 回歸]
부모와 자식 간의 신장을 조사하여, 일반적으로 장신인 부모의 아이는 장신이지만, 그 평균신장은 부모만큼 크지 않다는 것을 밝혀냈다. 다시 말하면 아이의 신장은 항상 일반적인 평균으로 되돌아가는 경향이 있다고 하여, 이것을 평균의 회귀현상이라고 함
- 회귀분석은 변수들 사이의 관계를 추정하는 분석방법이다. 기본적으로 변수들 사이에서 나타나는 경향성을 설명하는 것이 주 목적

회귀분석(Regression Analysis)



- 상관분석은 두 변수 사이에 선형적인 관련성이 있는지를 확인하는 단계이고, 회귀분석은 그 관련성을 직선이나 함수로 표현해서 한 변수를 다른 변수로 설명하거나 예측하는 단계



회귀분석(Regression Analysis)



회귀분석(Regression Analysis)



회귀분석(Regression Analysis)

선형회귀분석

- 두 변수들 사이의 관계를 분석하는 방법
- X변수 (독립변수, 등간 or 비율척도), Y변수 (종속변수, 등간 or 비율척도)
- 선형회귀모델: 독립변수와 종속변수 사이의 관계를 직선으로 표현
 - 단순선형회귀: 독립변수 1개
 - 다중선형회귀: 독립변수 2개 이상
- 목적
 - 두 변수 사이의 관계를 수치로 설명
 - 미래의 종속변수 값을 예측


$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_p X_{ip} + \varepsilon_i$$

여기서 β 는 회귀모델의 계수, ε 은 오차

회귀분석(Regression Analysis)

선형회귀의 기본 가정

- 종속 변수와 독립변수들 간에는 선형성이 성립한다.
- 독립 변수는 정확히 측정된 값으로 확률적으로 변하는 값이 아닌 고정된 값이다.
- 오차는 평균이 0, 분산이 σ^2 인 정규 분포를 따르며, 평균과 분산이 일정하다.
- 오차들 간은 서로 독립이다.
- 독립 변수들 간에는 다중 공선성(Multicollinearity)이 적어야 한다.



회귀분석(Regression Analysis)

다중공선성(multicollinearity)

- 회귀분석에서 독립변수들끼리 강한 선형관계가 있는 현상
예) x_1 이 아빠 키, x_2 가 엄마 키, x_3 가 부모 평균 키라면 x_3 는 x_1, x_2 와 강하게 관련
- 데이터가 조금만 바뀌어도 회귀계수가 크게 달라질 수 있음 불안정해짐
- 각 변수의 효과를 분리하기 어려움

독립변수 간 상관계수 확인

- 독립변수끼리 상관계수가 너무 높으면 다중공선성을 의심 (상관계수 $|r| > 0.7$ 또는 $|r| > 0.8$)
- Variance Inflation Factor (분산팽창계수, VIF)

$$VIF_j = \frac{1}{1 - R_j^2}$$

- R_j^2 는 특정 독립변수 x_j 를 나머지 독립변수들로 회귀했을 때의 결정계수
- 일반적으로 VIF가 5 이상이면 주의, 10 이상이면 심각한 다중공선성


회귀분석(Regression Analysis)

종속변수와 독립변수의 관계

- 회귀모델에서는 독립변수의 값에 대한 종속변수의 값이 오직 하나만 결정되는 함수적 관계가 아니고, 독립변수의 값이 종속변수 값의 확률분포에 따라 결정되는 **확률적 관계**
- 실제 데이터는 완전히 설명하지 못하는 요인 혹은 랜덤한 오차가 포함되어 있음
→ 키의 경우 유전, 영양, 운동, 수면, 환경, 측정오차들이 완전히 설명하지 못하는 요인


함수적 관계 (Deterministic Relationship)

X가 주어지면 Y가 하나로 결정되는 관계



확률적 관계 (Stochastic Relationship)


X가 주어져도 Y는 확률적으로 변하는 관계



회귀분석(Regression Analysis)

선형 회귀분석 모델

- 선형 회귀모델은 독립변수(X)와 종속변수(Y) 사이의 관계를 수식으로 표현하는 방법이다.
- 데이터를 이용하여 절편 β_0 과 기울기 β_1 (같은 회귀계수를 추정한다.
- 단순 선형회귀는 독립변수 1개를 사용하고, 다중 선형회귀는 2개 이상의 변수를 사용하여 값을 예측




The diagram illustrates the components of the linear regression equation $Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$. Each term is accompanied by a small icon and a label in Korean:

- Y_i : 종속변수 (Dependent Variable) - represented by a target icon.
- β_0 : 절편 (Y intercept) - represented by a coordinate system with a point on the y-axis.
- β_1 : 기울기 계수 (Slope Coefficient) - represented by a line with a positive slope.
- X_i : 독립변수 (Independent Variable) - represented by a scatter plot with a regression line.
- ϵ_i : 오차항 (Random Error term) - represented by a bell curve.


Below the equation, two brackets group the terms:

- A bracket under $\beta_0 + \beta_1 X_i$ is labeled "선형 성분 (Linear component)".
- A bracket under ϵ_i is labeled "오차 성분 (Random Error component)".



회귀분석(Regression Analysis)

- 어떤 선이 최선인가?



회귀분석(Regression Analysis)


잔차와 최소제곱법(Least Square Estimation)

- 잔차: 실제 관측값과 회귀모델 추정값의 차이

$$e_i = Y_i - \hat{Y}_i$$

- 최소 제곱법(Least Square Method): 다음 식을 최소로 하는 회귀모델 계수를 추정하는 방법

$$S = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)^2$$




회귀분석(Regression Analysis)

최소제곱법: 오차가 가장 작은 직선 찾기

- 최소제곱법은 실제 관측값과 회귀직선 사이의 오차를 제곱한 뒤 모두 더한 값이 가장 작아지는 직선을 찾는 방법
- 각 점에서 직선까지의 세로 거리인 잔차 e_i 를 이용하며, 목표는 $\sum e_i^2$ 를 최소화하는 것
- 같은 데이터라도 직선의 기울기와 절편이 달라지면 오차제곱합이 달라지며, 가장 작은 값을 만드는 직선이 최적의 회귀직선

Find the straight line that minimizes $\sum_{i=1}^n e_i^2$



회귀분석(Regression Analysis)

$$SST = SSR + SSE$$


- SST: Sum of Squares Total, 전체 변동량을 의미
 - 실제 관측값 y_i 가 평균값 $\bar{y}$ 으로부터 얼마나 떨어져 있는지를 나타냄
 - 데이터 자체가 원래 가지고 있는 총 변동성을 측정하는 값이다.
- SSR: Sum of Squares Regression, 회귀로 설명된 변동량을 의미
 - 회귀모델이 예측한 값 $\hat{y}_i$ 가 평균값 $\bar{y}$ 에서 얼마나 벗어나는지를 계산
 - 회귀직선이 데이터의 변동을 얼마나 잘 설명하는지를 보임
- SSE: Sum of Squares Error, 회귀로 설명하지 못한 오차 변동량을 의미한다.
 - 실제값 y_i 와 예측값 $\hat{y}_i$ 사이의 차이를 나타내며, 값이 작을수록 회귀모델이 데이터를 더 잘 설명

$$SST = SSR + SSE$$

→ 전체 변동량 = 회귀모델이 설명한 변동량 + 설명하지 못한 오차 변동량

회귀분석(Regression Analysis)

$$SST = SSR + SSE$$



회귀분석(Regression Analysis)

결정계수

- 결정계수 R^2 는 회귀모델이 종속변수 Y 의 변동을 얼마나 잘 설명하는지를 나타내는 지표
- 전체 변동(SST) 중에서 회귀모델이 설명한 변동(SSR)의 비율로 정의


$$R^2 = \frac{SSR}{SST}$$

- 결정계수의 값은 0과 1 사이에 존재
 - $R^2 = 1$ 이면 회귀직선이 데이터의 변동을 완벽하게 설명한다는 의미
 - $R^2 = 0$ 이면 회귀모델이 변수 간의 관계를 전혀 설명하지 못한다는 의미
- 따라서 결정계수는 회귀모델의 적합도를 평가하는 대표적인 척도로 사용되며, 일반적으로 값이 1에 가까울수록 데이터에 잘 맞는 회귀모델이라고 해석

회귀분석(Regression Analysis)

이상치의 영향

- 회귀분석은 데이터 전체의 오차를 최소화하기 때문에 멀리 떨어진 이상치(outlier)에 큰 영향을 받음
- 하나의 이상치만 추가되어도 회귀선의 기울기와 절편이 크게 변할 수 있음
- 따라서 이상치는 모델의 예측 성능과 해석 결과를 왜곡시킬 수 있어 주의가 필요




Classification Algorithm – Logistic Regression

Classification (분류)

- 분류는 새로운 관측값(데이터)이 여러 범주(category, class) 중 어느 하나에 속하는지를 식별하는 문제
- 출력값이 이산적(discrete) 혹은 범주형 변수(class)인 지도학습(supervised learning)의 한 유형

- **Classification with Linear regression?**




Classification Algorithm – Logistic Regression

Classification (분류)

- 분류는 새로운 관측값(데이터)이 여러 범주(category, class) 중 어느 하나에 속하는지를 식별하는 문제
- 출력값이 이산적(discrete) 혹은 범주형 변수(class)인 지도학습(supervised learning)의 한 유형

- **Classification with Linear regression?**




Classification Algorithm – Logistic Regression

Classification (분류)

- 분류는 새로운 관측값(데이터)이 여러 범주(category, class) 중 어느 하나에 속하는지를 식별하는 문제
- 출력값이 이산적(discrete) 혹은 범주형 변수(class)인 지도학습(supervised learning)의 한 유형

- **Classification with Linear regression?**




Classification Algorithm – Logistic Regression

Classification (분류)

- 분류는 새로운 관측값(데이터)이 여러 범주(category, class) 중 어느 하나에 속하는지를 식별하는 문제
- 출력값이 이산적(discrete) 혹은 범주형 변수(class)인 지도학습(supervised learning)의 한 유형

- **Classification with Linear regression?**




Classification Algorithm – Logistic Regression

Classification (분류)

- 분류는 새로운 관측값(데이터)이 여러 범주(category, class) 중 어느 하나에 속하는지를 식별하는 문제
- 출력값이 이산적(discrete) 혹은 범주형 변수(class)인 지도학습(supervised learning)의 한 유형

- **Classification with Linear regression?**




Classification Algorithm – Logistic Regression

Classification (분류)

- 분류는 새로운 관측값(데이터)이 여러 범주(category, class) 중 어느 하나에 속하는지를 식별하는 문제
- 출력값이 이산적(discrete) 혹은 범주형 변수(class)인 지도학습(supervised learning)의 한 유형

- **Classification with Linear regression?**




Classification Algorithm – Logistic Regression

Classification (분류)

- 분류는 새로운 관측값(데이터)이 여러 범주(category, class) 중 어느 하나에 속하는지를 식별하는 문제
- 출력값이 이산적(discrete) 혹은 범주형 변수(class)인 지도학습(supervised learning)의 한 유형

- **Classification with Linear regression?**



Classification Algorithm – Logistic Regression

Classification (분류)

- 분류는 새로운 관측값(데이터)이 여러 범주(category, class) 중 어느 하나에 속하는지를 식별하는 문제
- 출력값이 이산적(discrete) 혹은 범주형 변수(class)인 지도학습(supervised learning)의 한 유형

Linear regression을 통한 분류 → 한계 존재

- 선형회귀모델은 출력변수 Y 의 값이 $(-\infty, \infty)$ 에서 정의 됨
- 반면 분류(classification)의 출력 변수는 이산 값(e.g. 0과 1)을 가짐
- 분류하고자 하는 클래스(class)가 여러 개인 경우(multi-class classification) 선형 회귀 모델로 학습하기 어려움

Classification Algorithm – Logistic Regression

Classification (분류)

- 분류는 새로운 관측값(데이터)이 여러 범주(category, class) 중 어느 하나에 속하는지를 식별하는 문제
- 출력값이 이산적(discrete) 혹은 범주형 변수(class)인 지도학습(supervised learning)의 한 유형

Solution


- 분류 모델의 결과는 해당 class에 속할 확률 p (0~1)로 정의 (e.g. class 1에 속할 확률)
 - $X = (3, 4.1, 2.1)$ 일 때, class 1에 속할 확률은 0.9 (=class 1로 분류)
- 기존 선형회귀모델 출력변수 $Y(-\infty, \infty)$ 를 squeeze 하여 확률 과 연결
- 이진 분류(Binary classification)에서 여러 개의 클래스를 분류하는 다중 클래스 분류로 확장

Classification Algorithm – Logistic Regression

Odds

성공 확률(success probability, p)가 실패확률 ($1 - p$)에 비해 몇 배 더 높은가?

- p = probability of belonging to class 1(success), $odds = p / (1-p)$
- 0과 1사이를 갖는 p 를 가지고 0과 양의 무한대를 갖는 Odds로 변환, log를 씌워 logit으로 변환 가능
- 1에 가까운 p 로 예측 = 큰 수의 logit으로 예측 → logit에 대해 선형회귀함수를 학습 = 0과 1 사이를 예측하는 분류 함수 학습



$$\begin{aligned} 0 < p < 1 \\ \downarrow \\ 0 < Odds < \infty \\ \downarrow \\ -\infty < \mathit{logit} < \infty \\ \mathit{logit} = \ln(odds) = \ln\left(\frac{p}{1-p}\right) \end{aligned}$$

Classification Algorithm – Logistic Regression

Odds와 선형회귀모델에서 확률 p 의 관계


- 0과 1사이를 갖는 p 를 가지고 0과 양의 무한대를 갖는 Odds로 변환, log를 씌워 logit으로 변환 가능
- 1에 가까운 p 로 예측 = 큰 수의 logit으로 예측 → logit에 대해 선형회귀함수를 학습 = 0과 1 사이를 예측하는 분류 함수 학습

$$\begin{array}{ccc} y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q + \varepsilon & & \text{logit} = \ln(\text{odds}) = \ln\left(\frac{p}{1-p}\right) \\ \swarrow \quad \searrow & & \\ \text{Logit} = \ln\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q & & \\ \downarrow & & \\ p = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q)}} \end{array}$$

Classification Algorithm – Logistic Regression

Logistic regression

- 어떤 현상에 대한 관측데이터 x 와 이들이 어떠한 클래스(class) 또는 범주(label)에 속하는지에 대한 정보 Y 가 존재
- Y 가 두 개의 클래스로 이루어진 경우, 하나의 데이터가 successive class ($Y=1$) 일 확률을 아래 식으로 추정 가능



$$f(x) = \frac{1}{1 + e^{-x}} = \frac{e^x}{e^x + 1}$$

- a.k.a. softmax function
- $0 < f(x) < 1$
- $f(0) = 0.5$
- Symmetric at $x = 0$

$$p = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q)}}$$


<Logistic regression probability equation>

Classification Algorithm – Logistic Regression

Logistic regression

- 어떤 현상에 대한 관측데이터 X 와 이들이 어떠한 클래스(class) 또는 범주(label)에 속하는지에 대한 정보 Y 가 존재
- Y 가 두 개의 클래스로 이루어진 경우, 하나의 데이터가 successive class ($Y=1$) 일 확률을 아래 식으로 추정 가능

- **Classification with Logistic regression**



Classification Algorithm – Logistic Regression

Logistic regression

Logistic regression = p 는 class 1일 확률이고 이를 logit의 형태로 변환하여 선형회귀함수와 연결한 모델
그럼 가중치(=weight) $\beta_0, \beta_1, \dots, \beta_p$ 는 어떻게 구할까?

기계학습 모델 학습의 의미

- 모델의 학습 과정 = 모델의 성능이 높도록 모델을 구성하는 가중치(=weight)를 정하는 과정
- 모델을 학습할 땐, 성능을 **최대화**(=maximization)하거나 손실을 **최소화**(=minimization)하는 가중치 계산

예측 p	예측 $1 - p$	실제 class
0.8	0.2	1
0.9	0.1	1
0.1	0.9	0
0.2	0.8	0

<성능이 좋은 분류 모델 A>

예측 p	예측 $1 - p$	실제 class
0.1	0.9	1
0.4	0.6	1
0.7	0.3	0
0.6	0.4	0

<성능이 나쁜 분류 모델 B>

Classification Algorithm – Logistic Regression

Logistic regression

Logistic regression = p 는 class 1일 확률이고 이를 logit의 형태로 변환하여 선형회귀함수와 연결한 모델

그럼 가중치(=weight) $\beta_0, \beta_1, \dots, \beta_p$ 는 어떻게 구할까?

→ 두 모델 성능 비교는 성공 예측일 땐 p , 실패 예측일 땐 $1 - p$ 를 곱한 값으로 비교

- A: $0.8 \times 0.9 \times 0.9 \times 0.8 = \underline{\mathbf{0.5184}}$

- B: $0.1 \times 0.4 \times 0.3 \times 0.4 = 0.0048$

$0.5184 > 0.0048$, 모델 A wins!

→ 확률 곱이 최대가 되는 모델이 좋은 모델

예측 p	예측 $1 - p$	실제 class
0.8	0.2	1
0.9	0.1	1
0.1	0.9	0
0.2	0.8	0

<성능이 좋은 분류 모델 A>

예측 p	예측 $1 - p$	실제 class
0.1	0.9	1
0.4	0.6	1
0.7	0.3	0
0.6	0.4	0

<성능이 나쁜 분류 모델 B>

Classification Algorithm – Logistic Regression

Logistic regression

- **Objective – 최대가능도 추정(Maximum likelihood estimation: MLE)**

- i 번째 데이터포인트의 입력변수들: x_i , 출력변수(클래스) $y_i \in \{0,1\}$
- 하나의 데이터포인트 (x_i, y_i) 에 대해, $y_i = 1$ 일 확률: π_i

$$P(y_i = 1|x_i, \beta) = \sigma(\text{logit}) = \sigma(\beta^T x_i) = \frac{1}{1 + e^{-\beta^T x_i}} = \pi_i$$

logistic (or softmax, sigmoid) function: $\sigma(x) = \frac{1}{1 + e^{-x}}$

$$\text{logit} = \beta^T x_i = (\beta_0, \beta_1, \dots, \beta_p) \begin{pmatrix} 1 \\ x_{i1} \\ x_{i2} \\ \dots \\ x_{ip} \end{pmatrix} = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} = \sum_{j=0}^p \beta_j x_{ij}$$

Classification Algorithm – Logistic Regression

Logistic regression

- **Objective – 최대가능도 추정(Maximum likelihood estimation: MLE)**

- 하나의 데이터포인트 (x_i, y_i) 에 대한 likelihood

$$P(y_i|x_i, \beta) = \begin{cases} \pi_i & \text{if } y_i = 1 \\ 1 - \pi_i & \text{if } y_i = 0 \end{cases} = \pi_i^{y_i}(1 - \pi_i)^{1-y_i}$$

- 모든 포인트에 대한 전체 likelihood

$$P(Y|X, \beta) = \prod_{i=1}^n P(y_i|x_i, \beta) = \prod_{i=1}^n \pi_i^{y_i}(1 - \pi_i)^{1-y_i}$$

- 모든 포인트에 대한 log-likelihood → **Want to maximize the log-likelihood**

$$\log P(Y|X, \beta) = \sum_{i=1}^n y_i \log \pi_i + (1 - y_i) \log(1 - \pi_i)$$

Classification Algorithm – Logistic Regression

Logistic regression

- **Objective – 최대가능도 추정(Maximum likelihood estimation: MLE)**

- 모든 포인트에 대한 log-likelihood → **Want to maximize the log-likelihood**

$$\log P(Y|X, \beta) = \sum_{i=1}^n y_i \log \pi_i + (1 - y_i) \log(1 - \pi_i)$$

- Maximize the log-likelihood = **Minimize the negative log-likelihood**

Log-likelihood: $\log P(Y|X, \beta) = \sum_{i=1}^n y_i \log \pi_i + (1 - y_i) \log(1 - \pi_i)$

Negative
log-likelihood (NLL): $-\log P(Y|X, \beta) = \sum_{i=1}^n -y_i \log \pi_i - (1 - y_i) \log(1 - \pi_i)$

NLL is a **loss function** of logistic regression model.
NLL of logistic regression = **Cross-entropy**

Classification Algorithm – Logistic Regression

Logistic regression

- **Gradient descent: 목적함수를 최소화 하는 coefficient를 찾는 학습 방법**

- Update β to reduce the loss function (or negative log-likelihood).
- Gradient descent method

- Gradient descent의 자세한 내용은 Neural network에서 설명

- 1. Randomly initialize $\beta = (\beta_0, \beta_1, \beta_2, \dots, \beta_p)$.

- 2. for step in range(0, num_steps):

- 2-1. Calculate the derivative of loss function

- 2-2. Update β_j s (for $j = 0, 1, \dots, p$)

$$\beta_j \leftarrow \beta_j - \eta \frac{\partial J}{\partial \beta_j}$$

scalar version

- 2-2. Update β

$$\beta \leftarrow \beta - \eta \frac{\partial J}{\partial \beta}$$

vector version

$$J = \frac{1}{n} \sum_{i=1}^n [-y_i \log \pi_i - (1 - y_i) \log(1 - \pi_i)]$$

$$\pi_i = \sigma(\beta^T x_i) = \frac{1}{1 + e^{-\beta^T x_i}}$$

[Loss function in logistic regression (and neural network)]

Classification Algorithm – Logistic Regression

Logistic regression

$$\frac{\partial}{\partial \beta_j} NLL = \sum_{i=1}^n \left(-y_i \cdot \frac{\partial}{\partial \beta_j} \log \pi_i - (1 - y_i) \cdot \frac{\partial}{\partial \beta_j} \log(1 - \pi_i) \right) = \sum_{i=1}^n (\pi_i - y_i) x_{ij}$$

$$\frac{\partial}{\partial \beta_j} \log \pi_i = \frac{1}{\pi_i} \frac{\partial}{\partial \beta_j} \pi_i \quad \frac{\partial}{\partial \beta_j} \log(1 - \pi_i) = \frac{1}{(1 - \pi_i)} \left(-\frac{\partial}{\partial \beta_j} \pi_i \right)$$


$$\frac{\partial}{\partial \beta_j} \pi_i = \frac{\partial}{\partial \beta_j} \sigma(\beta^T x_i) = \sigma(\beta^T x_i) \{1 - \sigma(\beta^T x_i)\} x_{ij} = \pi_i (1 - \pi_i) x_{ij}$$

$$\begin{aligned} -y_i \cdot \frac{\partial}{\partial \beta_j} \log \pi_i - (1 - y_i) \cdot \frac{\partial}{\partial \beta_j} \log(1 - \pi_i) &= -y_i (1 - \pi_i) x_{ij} - (1 - y_i) (-\pi_i x_{ij}) \\ &= -y_i x_{ij} + y_i \pi_i x_{ij} + \pi_i x_{ij} - y_i \pi_i x_{ij} = (\pi_i - y_i) x_{ij} \end{aligned}$$

Classification Algorithm – Logistic Regression

Logistic regression – Multi-class classification

- One vs others



Classification Algorithm – Logistic Regression

분류 모델 평가 – 성능 (Confusion Matrix)

- 데이터의 실제 클래스(Y)와 모델에 의해 예측된 클래스($\hat{Y}$)를 비교하는 행렬
- 클래스 별로 잘 분류된 포인트와 잘못 분류된 포인트의 수를 정리한 행렬

		Predicted class	
		1 (+)	0 (-)
Actual class	1 (+)	n_{11}	n_{10}
	0 (-)	n_{01}	n_{00}

< Confusion matrix format >

- Number of points classified correctly: $n_{11} + n_{00}$
- Number of points misclassified: $n_{10} + n_{01}$

분류정확도(Accuracy) : $\frac{n_{11} + n_{00}}{n_{11} + n_{10} + n_{01} + n_{00}}$


오분류율(Misclassification error)
: $1 - \text{Accuracy}$

Classification Algorithm – Logistic Regression

분류 모델 평가 – 성능 (Confusion Matrix)

- 데이터의 실제 클래스(Y)와 모델에 의해 예측된 클래스($\hat{Y}$)를 비교하는 행렬
- 클래스 별로 잘 분류된 포인트와 잘못 분류된 포인트의 수를 정리한 행렬

❖ 예제1: 소매점에서 고객 구매 이력 데이터를 기반으로, 이 고객이 꾸준히 방문하는 VIP 고객인지 아닌지 예측하고자 함. (Test set = 10명의 고객)



Classification Algorithm – Logistic Regression

분류 모델 평가 – 성능 (Confusion Matrix)

- 데이터의 실제 클래스(Y)와 모델에 의해 예측된 클래스($\hat{Y}$)를 비교하는 행렬
- 클래스 별로 잘 분류된 포인트와 잘못 분류된 포인트의 수를 정리한 행렬

❖ Cut-off = 0.4인 경우

▶ $P(Y = 1) \geq 0.4$ 이면, $\hat{Y} = 1$

X_1	...	X_p	Y	$P(Y = 1)$	$\hat{Y}$
			1	0.97	1
			0	0.15	0
			1	0.54	1
			0	0.58	1
			0	0.24	0
			1	0.75	1
			0	0.42	1
			1	0.80	1
			1	0.45	1
			0	0.70	1

		Predicted class	
		1 (+)	0 (-)
Actual class	1 (+)	5	0
	0 (-)	3	2

- Accuracy = $7/10 = 0.7$
- Misclassification error = $3/10 = 0.3$

Classification Algorithm – Logistic Regression

분류 모델 평가 – 성능 (Confusion Matrix)

- 데이터의 실제 클래스(Y)와 모델에 의해 예측된 클래스($\hat{Y}$)를 비교하는 행렬
- 클래스 별로 잘 분류된 포인트와 잘못 분류된 포인트의 수를 정리한 행렬

❖ Cut-off = 0.5인 경우

▶ $P(Y = 1) \geq 0.5$ 이면, $\hat{Y} = 1$

X_1	...	X_p	Y	$P(Y = 1)$	$\hat{Y}$
			1	0.97	1
			0	0.15	0
			1	0.54	1
			0	0.58	1
			0	0.24	0
			1	0.75	1
			0	0.42	0
			1	0.80	1
			1	0.45	0
			0	0.70	1

		Predicted class	
		1 (+)	0 (-)
Actual class	1 (+)	4	1
	0 (-)	2	3

- Accuracy = $7/10 = 0.7$
- Misclassification error = $3/10 = 0.3$

Classification Algorithm – Logistic Regression

분류 모델 평가 – 성능 (Confusion Matrix)

- 데이터의 실제 클래스(Y)와 모델에 의해 예측된 클래스($\hat{Y}$)를 비교하는 행렬
- 클래스 별로 잘 분류된 포인트와 잘못 분류된 포인트의 수를 정리한 행렬

❖ Cut-off = 0.6인 경우

▶ $P(Y = 1) \geq 0.6$ 이면, $\hat{Y} = 1$

X_1	...	X_p	Y	$P(Y = 1)$	$\hat{Y}$
			1	0.97	1
			0	0.15	0
			1	0.54	0
			0	0.58	0
			0	0.24	0
			1	0.75	1
			0	0.42	0
			1	0.80	1
			1	0.45	0
			0	0.70	1

		Predicted class	
		1 (+)	0 (-)
Actual class	1 (+)	3	2
	0 (-)	1	4

- Accuracy = $7/10 = 0.7$
- Misclassification error = $3/10 = 0.3$

Classification Algorithm – Logistic Regression

분류 모델 평가 – 성능 (Confusion Matrix)

- 데이터의 실제 클래스(Y)와 모델에 의해 예측된 클래스($\hat{Y}$)를 비교하는 행렬
- 클래스 별로 잘 분류된 포인트와 잘못 분류된 포인트의 수를 정리한 행렬

❖ Cut-off value가 0.4, 0.5, 0.6 일 때,

- ▶ Confusion matrix의 성분에는 변화가 있지만,
- ▶ 모두 accuracy = 0.7, misclassification rate = 0.3

		Predicted class	
		1 (+)	0 (-)
Actual class	1 (+)	5	0
	0 (-)	3	2

		Predicted class	
		1 (+)	0 (-)
Actual class	1 (+)	4	1
	0 (-)	2	3

		Predicted class	
		1 (+)	0 (-)
Actual class	1 (+)	3	2
	0 (-)	1	4

Which cut-off value is the best?
→ How to measure the performance of classification model

Classification Algorithm – Logistic Regression

분류 모델 평가 – 성능 (Confusion Matrix)

- 데이터의 실제 클래스(Y)와 모델에 의해 예측된 클래스($\hat{Y}$)를 비교하는 행렬
- 클래스 별로 잘 분류된 포인트와 잘못 분류된 포인트의 수를 정리한 행렬

❖ 예제: 폐 MRI 사진을 이용하여 암 환자를 분류

- ▶ 학습 데이터를 이용하여 두 개의 분류 모델을 학습
- ▶ 두 모델의 예측 성능을 검증하기 위하여, test set 1000명
(암 환자: 10명, 정상 환자: 990명)에 대해 분류한 결과를 비교
- ▶ positive class: $Y = 1$ (암 환자)

Model 1		Predicted class	
		1 (+)	0 (-)
Actual class	1 (+)	0	10
	0 (-)	0	990

- Accuracy = $990/1000 = 0.99$
- Misclassification error = $10/1000 = 0.01$

Model 2		Predicted class	
		1 (+)	0 (-)
Actual class	1 (+)	6	4
	0 (-)	50	940

- Accuracy = $946/1000 = 0.946$
- Misclassification error = $54/1000 = 0.054$


Which model is better?

Classification Algorithm – Logistic Regression

분류 모델 평가 – 성능 (Confusion Matrix)

❖ 4 outcomes

- ▶ True positive (TP): correct positive prediction
- ▶ False positive (FP): incorrect positive prediction
- ▶ True negative (TN): correct negative prediction
- ▶ False negative (FN): incorrect negative prediction



출처: <https://classeval.wordpress.com/introduction/basic-evaluation-measures/>

Classification Algorithm – Logistic Regression

분류 모델 평가 – 성능 (Confusion Matrix)


❖ 각 클래스의 입장에서,

		Predicted class	
		1 (+)	0 (-)
Actual class	1 (+)	TP	FN
	0 (-)	FP	TN

- Sensitivity (Recall, True positive rate) = $TP / (TP + FN)$
- Specificity (True negative rate) = $TN / (FP + TN)$
- Precision = $TP / (TP + FP)$
- False negative rate (Type I error) = $1 - \text{Sensitivity} = FN / (TP + FN)$
- False positive rate (Type II error) = $1 - \text{Specificity} = FP / (FP + TN)$

Classification Algorithm – Logistic Regression

분류 모델 평가 – 성능 (Confusion Matrix)



출처: <https://classeval.wordpress.com/introduction/basic-evaluation-measures/>

Classification Algorithm – Logistic Regression

분류 모델 평가 – 성능 (Confusion Matrix)

Cut-off = 0.4		Predicted class	
		1 (+)	0 (-)
Actual class	1 (+)	5	0
	0 (-)	3	2

- Recall = $5 / (5 + 0) = 1$
- Precision = $5 / (5 + 3) = 0.625$
- F1-score = **0.769* (Best)**

Cut-off = 0.5		Predicted class	
		1 (+)	0 (-)
Actual class	1 (+)	4	1
	0 (-)	2	3

- Recall = $4 / (4 + 1) = 0.8$
- Precision = $4 / (4 + 2) = 0.667$
- F1-score = 0.727

Cut-off = 0.6		Predicted class	
		1 (+)	0 (-)
Actual class	1 (+)	3	2
	0 (-)	1	4

- Recall = $3 / (3 + 2) = 0.6$
- Precision = $3 / (3 + 1) = 0.75$
- F1-score = 0.667

Classification Algorithm – Logistic Regression

분류 모델간 평가

Model 1		Predicted class	
		1 (+)	0 (-)
Actual class	1 (+)	0	10
	0 (-)	0	990

- Accuracy = $990/1000 = 0.99$
- Misclassification error = $10/1000 = 0.01$
- Recall = $0 / (0 + 10) = 0$
- Specificity = $940 / (0 + 940) = 1$
- Precision = $0 / (0 + 0) = \text{Not available}$
- BCR = $\sqrt{0 * 1} = 0$
- F1-score = Not available

Model 2		Predicted class	
		1 (+)	0 (-)
Actual class	1 (+)	6	4
	0 (-)	50	940

- Accuracy = $946/1000 = 0.946$
- Misclassification error = $54/1000 = 0.054$
- Recall = $6 / (6 + 4) = 0.6$
- Specificity = $940 / (50 + 940) = 0.950$
- Precision = $6 / (6 + 50) = 0.107$
- BCR = $\sqrt{0.6 * 0.107} = 0.755^* (\text{Best})$
- F1-score = $0.182^* (\text{Best})$