

데이터 시각화

Hunsik Shin

Department of Industrial and Data Engineering








{hunsik.shin}@hongik.ac.kr

데이터 시각화

- 단변량
 - 양적변수: 히스토그램, 박스플롯(상자그림)
 - 범주형 변수: 막대그래프, 파이차트
- 이변량
 - 양적 vs. 양적: 산점도, 산점도 행렬, 버블차트 등
 - 범주형 vs. 범주형: mosaic plot
 - 양적 vs. 범주형: 박스플롯 들
- 다변량
 - Radar/Spyder 차트, 나이팅게일 차트, heatmap


데이터 시각화

- Histogram



데이터 시각화

- Histogram





- binwidth:** The width of the bins. Can be specified as a numeric value or as a function that takes x after scale transformation as input and returns a single numeric value.
- bins:** Number of bins. Overridden by binwidth. Defaults to 30.

데이터 시각화

- **Density plot**

밀도 추정 그래프(주로 커널 밀도 추정, Kernel Density Estimation)는 히스토그램을 부드러운 곡선 형태로 만든 것
각 데이터 포인트에 커널 함수(주로 가우시안)를 적용해 합친 결과물.



- > **표현 방식:** 연속적인 곡선
- > **Y축:** 밀도(Density) (곡선 아래의 전체 면적의 합 = 1)



출처: <https://www.r-graph-gallery.com/>

데이터 시각화


- Scatter Plot(산점도)



출처: <https://www.r-graph-gallery.com/>

데이터 시각화

- Scatterplot matrix







출처: <https://www.r-graph-gallery.com/>

데이터 시각화

• Bubble Plot



- 산점도(Scatter Plot)에 데이터의 크기 차원을 하나 더 추가한 그래프
- 산점도가 두 변수 사이의 관계(좌표)만 보여준다면, 버블 차트는 그 지점에 놓인 원의 크기(면적)를 통해 세 번째 정보를 시각화



출처: <https://www.r-graph-gallery.com/>



데이터 시각화

- Radar/Spyder Chart



데이터 시각화







- Box Plot



Anatomy of a boxplot - *Explanation* - *Image source*



데이터 시각화

- Box Plot



데이터 시각화

- Heatmap




<Heatmap with Dendrogram>

출처: <https://www.r-graph-gallery.com/>

데이터 시각화

- Pie Chart



출처: <https://www.r-graph-gallery.com/>

데이터 시각화


- Circular stacked barchart




출처: <https://www.r-graph-gallery.com/>

The R Graph Gallery


Distribution




Correlation




Ranking



Part of a whole




Evolution



WAYS BY WHICH DATA VISUALIZATION HELPS IN DECISION MAKING



QUICKER
DECISION MAKING



QUICKER
IDENTIFICATION
OF PATTERNS



BETTER
ACCURACY




BETTER
COMMUNICATION


데이터 시각화 활용

- 질병관리청
 - COVID-19 Dashboard
 - <https://ncv.kdca.go.kr/covdash/biz/dsbd/covDsbdOcrn.do>
- Centers for Disease Control and Prevention
 - CDC COVID Data Tracker
 - <https://covid.cdc.gov/covid-data-tracker>

데이터 시각화 활용



데이터 시각화 활용




- 구글 검색을 할 때 우리는 빅데이터를 사용
- 구글 색인-검색할 수 있는 모든 웹페이지에 대한 아카이브의 크기는 대략 100페타바이트(또는 1억 기가바이트).
- 1997년 창립된 구글을 전 세계적으로 유명하게 만든 것은 구글 페이지랭크(pagerank)로 알고리즘
- 페이지랭크는 구글의 창업자인 래리 페이지와 세르게이 브린이 구글을 만들기 전, 스탠퍼드 대학에서 연구할 때 개발

- 원리는 더 많은 페이지들이 특정 페이지에 링크될수록 그 특정 페이지의 우선순위가 높아진다는 것
- 권위가 높은 페이지일수록 인용될 가능성이 높아짐
- 그 사이트에 링크된 비슷한 키워드를 얼마나 많은 사이트들이 사용했는가?, 그리고 그 링크 페이지는 얼마나 권위있는(자주 링크되는) 것인가를 기준으로, 구글은 인덱스의 모든 페이지에 순위를 매겨서 첫 검색 알고리즘을 만듦
- 현재 구글은 전체 인터넷 검색 사용량의 89%를 차지하고 있다.

PageRank

• Graph의 정의


- 그래프(graph, G)란 정점(vertex, V)와 그 노드를 연결하는 엣지(edge, E)를 모아놓은 구조
- 개체와 개체 간의 관계를 표현하는데 효과적임
- $G = (V, E)$
 - 정점/노드(Vertex/Node, V): 여러 가지 특성을 갖는 개체
 - 간선/엣지(Edge, E): 개체와 개체 간의 관계




PageRank

- **Graph의 정의**

- 간선/엣지(Edge, E): 개체와 개체 간의 관계. Edge의 종류에 따른 분류
 - Directed/Undirected: Edge의 방향성이 있음/없음



Directed Graph




Undirected Graph


PageRank

• Graph의 정의

- 간선/엣지(Edge, E): 개체와 개체 간의 관계. Edge의 종류에 따른 분류
 - Weighted/Unweighted: Edge의 방향성이 있음/없음



Weighted Graph




Unweighted Graph

PageRank

• Graph의 정의


- 간선/엣지(Edge, E): 개체와 개체 간의 관계. Edge의 종류에 따른 분류
 - Directed/Undirected: Edge의 방향성이 있음/없음
 - Weighted/Unweighted: Edge의 방향성이 있음/없음
 - 두 가지 특성을 모두 갖는 그래프도 존재



PageRank

- 웹페이지들을 Graph 구조로 나타내 봅시다


- Node: 웹페이지
- Edge: 웹페이지에서 웹페이지로 이동하는 link



PageRank

- **PageRank: 웹사이트의 중요도를 측정하는 알고리즘**


- 1995년 Google의 창립자 Larry Page와 Sergey Brin이 고안한 알고리즘
- Search Engine의 검색 결과물의 향상을 위하여 고안
- 수많은 웹사이트 중, 어떤 웹사이트를 검색 결과로 제공할 것인가?
 - PageRank로 각 웹사이트의 중요도를 산출
 - 특정 검색어를 입력 시, 중요도가 높은 페이지를 검색 결과로!



PageRank

- Idea

- 1. 다른 웹페이지에서 들어오는 링크가 많을 수록 중요도는 높다
- 2. "중요한" 웹페이지에서 들어오는 링크가 많을 수록 중요도는 높다



PageRank

- **Algorithm**

- 반복적으로(iterative) 계산됨

$$S(V_i) = \frac{(1-d)}{|V|} + d * \sum_{j \in In(V_i)} \frac{1}{|Out(V_j)|} S(V_j)$$

$S(V_i)$: V_i 의 pagerank score

$|V|$: 그래프에 존재하는 총 노드의 수

d : damping factor (링크를 통해 타 페이지로 이동할 확률)


$In(V_i)$: V_i 로 들어오는 엣지가 연결하는 노드들

$|Out(V_j)|$: V_j 에서 나가는 엣지가 연결하는 노드의 수

PageRank

• Algorithm 예시

- Damping factor = 0.85
- 초기 값은 모든 노드들이 동일한 값
 - $S(A) = S(B) = S(C) = S(D) = 0.25$



$$S(V_i) = \frac{(1-d)}{|V|} + d * \sum_{j \in In(V_i)} \frac{1}{|Out(V_j)|} S(V_j)$$

	1	2	3
A	0.2500		
B	0.2500		
C	0.2500		
D	0.2500		

PageRank


• Algorithm 예시

- Damping factor = 0.85
- A의 PageRank score (2nd iteration)

$$S(V_i) = \frac{(1-d)}{|V|} + d * \sum_{j \in In(V_i)} \frac{1}{|Out(V_j)|} S(V_j)$$

$In(A)$: A로 들어오는 노드는 C

$|Out(C)|$: C에서 나가는 노드는 A, B, D → 3
 $S(C)$: **0.25**



	1	2	3
A	0.2500	0.1083	
B	0.2500		
C	0.2500		
D	0.2500		

$$S(A) = \frac{(1 - 0.85)}{4} + 0.85 * \left(\frac{1}{3} * \mathbf{0.2500} \right) = \mathbf{0.1083}$$


PageRank

• Algorithm 예시

- Damping factor = 0.85
- B의 PageRank score (2nd iteration)

$$S(V_i) = \frac{(1-d)}{|V|} + d * \sum_{j \in In(V_i)} \frac{1}{|Out(V_j)|} S(V_j)$$

$In(B)$: B로 들어오는 노드는 A, C



$|Out(A)|$: A에서 나가는 노드는 B, C $\rightarrow 2$

$S(A)$: 0.25

$|Out(C)|$: C에서 나가는 노드는 A, B, D $\rightarrow 3$

$S(C)$: 0.25

	1	2	3
A	0.2500	0.1083	
B	0.2500	0.2146	
C	0.2500		
D	0.2500		

$$S(B) = \frac{(1-0.85)}{4} + 0.85 * \left(\frac{1}{2} * 0.2500 + \frac{1}{3} * 0.2500 \right) = 0.2146$$


PageRank

• Algorithm 예시

- Damping factor = 0.85
- C의 PageRank score (2nd iteration)

$$S(V_i) = \frac{(1-d)}{|V|} + d * \sum_{j \in In(V_i)} \frac{1}{|Out(V_j)|} S(V_j)$$

$In(C)$: C로 들어오는 노드는 A, D



$|Out(A)|$: A에서 나가는 노드는 B, C $\rightarrow 2$

$S(A)$: 0.25

$|Out(D)|$: D에서 나가는 노드는 C $\rightarrow 1$

$S(D)$: 0.25

	1	2	3
A	0.2500	0.1083	
B	0.2500	0.2146	
C	0.2500	0.3563	
D	0.2500		

$$S(C) = \frac{(1-0.85)}{4} + 0.85 * \left(\frac{1}{2} * 0.2500 + \frac{1}{1} * 0.2500 \right) = 0.3563$$


PageRank

• Algorithm 예시

- Damping factor = 0.85
- D의 PageRank score (2nd iteration)

$$S(V_i) = \frac{(1-d)}{|V|} + d * \sum_{j \in In(V_i)} \frac{1}{|Out(V_j)|} S(V_j)$$

$In(D)$: D로 들어오는 노드는 B, C



$|Out(B)|$: B에서 나가는 노드는 D $\rightarrow$ 1

$S(B)$: 0.25

$|Out(C)|$: C에서 나가는 노드는 A, B, D $\rightarrow$ 3

$S(C)$: 0.25

	1	2	3
A	0.2500	0.1083	
B	0.2500	0.2146	
C	0.2500	0.3563	
D	0.2500	0.3208	

$$S(D) = \frac{(1-0.85)}{4} + 0.85 * \left(\frac{1}{1} * 0.2500 + \frac{1}{3} * 0.2500 \right) = 0.3208$$


PageRank

• Algorithm 예시

- Damping factor = 0.85
- D의 PageRank score (3rd iteration)

$$S(V_i) = \frac{(1-d)}{|V|} + d * \sum_{j \in In(V_i)} \frac{1}{|Out(V_j)|} S(V_j)$$

$In(D)$: D로 들어오는 노드는 B, C



$|Out(B)|$: B에서 나가는 노드는 D $\rightarrow$ 1

$S(B)$: **0.2146**

$|Out(C)|$: C에서 나가는 노드는 A, B, D $\rightarrow$ 3

$S(C)$: **0.3563**

	1	2	3
A	0.2500	0.1083	0.1384
B	0.2500	0.2146	0.1845
C	0.2500	0.3563	0.3563
D	0.2500	0.3208	0.3208


$$S(D) = \frac{(1-0.85)}{4} + 0.85 * \left(\frac{1}{1} * \mathbf{0.2146} + \frac{1}{3} * \mathbf{0.3563} \right) = \mathbf{0.3208}$$

Google의 독감 예보

- 2013년 미국에서 계절 인플루엔자(독감)가 유행. 독감으로 인한 사망자가 이미 100명을 넘어서자 일부 지역에서 공중보건 비상사태를 선포
- 미 질병통제예방센터(CDC)에 따르면 122개 도시의 사망자를 조사한 결과, 전체 사망자 중 7.3%가 감기나 폐렴으로 숨진 것으로 파악
- CDC가 발표하는 독감 관련 보고서보다 더 앞서 독감 바이러스 확산을 예측하는 곳이 있었는데 바로 세계적인 IT 기업 구글
- 구글은 독감 증세 환자가 늘면 '감기'와 관련된 단어를 검색하는 빈도가 함께 증가한다는 패턴을 발견
- 이를 질병통제예방센터 데이터와 비교해본 결과 검색 빈도와 실제 독감 증세를 보인 환자 숫자 사이에 밀접한 상관관계가 있다는 사실을 밝힘
- 구글은 이 같은 분석을 바탕으로 웹사이트를 통해 시간 및 지역별 독감 유행 정보를 미국 보건당국보다 한발 앞서 제공하고 있다

Google의 독감 예보

- 구글이 지난 2008년 11월부터 선보인 '독감 트렌드' 서비스는 전 세계 각지에서 '독감 증세', '독감 치료' 등 독감과 관련된 검색어의 입력 빈도를 지역별로 파악해 독감 유행 수준을 '매우 낮음'부터 '매우 높음'까지 5개 등급으로 구분해 표시한다.
- 특정 지역에서 발열이나 기침 등 독감 관련 검색이 늘어나면 검색어와 관련된 IP 주소를 지도에 추가해 해당 지역의 독감 유행 수준 등급이 거의 실시간으로 표시된다.



지진예보 - 지진희 갤러리

최신뉴스

"안전처 못 믿겠다"...네티즌이 새 지진 알림시스템 개발

송고 2016-09-20 15:28

네티즌들의 유희 이용한 집단지성과 '텔레그램' 이용

(서울=연합뉴스) 이대희 기자 = 최근 열흘 사이 경주 지역에 강진이 잇따라 발생했지만 이를 신속히 알려야 하는 국민안전처가 제 역할을 하지 못해 비판을 사고 있다.

한 개발자가 인터넷 메신저와 집단지성을 이용해 지진 관련 이상 상황을 신속히 알릴 수 있는 서비스를 개발해 눈길을 끌고 있다.

오늘만 이 가격!
한정특가 품절 전 구경하세요

GS SHOP

20일 인터넷 커뮤니티 '클리앙'에 따르면 '이프로부족'이라는 한 개발자는 규모 4.5 지진이 난 19일 저녁 '지진이면 텔레그램으로 알림 받기'라는 글로 자신이 개발한 프로그램을 소개했다.

이 개발자는 지진동이 느껴지면 최단시간에 사회관계망서비스(SNS)인 '텔레그램'으로 알림을 받을 수 있는 시스템을 구현했다.

'지진희알림'이라는 이름의 이 시스템은 텔레그램을 스마트폰에 설치하고 가입주소 (https://telegram.me/jijinhee_noti)로 들어가면 가입할 수 있다.

그는 인터넷 사용자들이 지진이 나면 온라인 커뮤니티 사이트 디시인사이드 게시판 중 텔런트 '지진희' 갤러리에 집중적으로 글을 올린다는 점에서 착안했다.

지진희의 이름 앞이 '지진'이라는 점을 이용한 일종의 언어유희를 지진 알림에 사용하는 것이다.

실제로 개발자가 19일 지진희 갤러리를 분석한 결과 지진이 발생한 오후 8시33분에서 불과 1분이 지난 8시34분에 첫 지진 관련 글이 올라왔다.

2분이 지난 8시35분까지 지진희 갤러리에 올라온 글은 50개가 넘어섰다. 지진희 갤러리에 이렇게 폭발적으로 글이 올라오는 일은 사실상 지진이 발생했을 때 이외에는 없다.

이 개발자는 지진희 갤러리를 30초마다 검사해 1분 안에 글 20개가 올라오면 이상 상황으로 간주, 즉시 텔레그램으로 알림을 보내는 시스템을 구현했다.

지진예보 - 지진희 갤러리

