

기초 통계

Hunsik Shin

Department of Industrial and Data Engineering

{hunsik.shin}@hongik.ac.kr

기초 통계 용어

1. 모집단 Population

- 모집단은 연구 또는 분석의 관심 대상이 되는 전체 집합
- 통계분석을 통해 최종적으로 알고자 하는 대상 전체를 의미

2. 표본 Sample


- 표본은 모집단 중에서 실제 조사 또는 관측이 이루어진 일부 집합
- 모집단 전체를 조사하기 어려울 때, 모집단을 대표할 수 있도록 선택된 대상

3. 모수 Parameter


- 모수는 모집단의 특성을 나타내는 수치
모집단 전체를 기준으로 계산되는 값이며, 연구자가 궁극적으로 알고자 하는 값

4. 통계량 Statistic

- 통계량은 표본자료를 이용해 계산한 수치
- 표본의 특성을 요약한 값이며, 모집단의 모수를 추정하는 데 활용



기초 통계 용어




기초 통계 용어

- **통계적 추론:** 표본에서 얻은 정보를 바탕으로 모집단의 특성, 즉 모수를 추정하거나 판단하는 과정
- **확률:** 특정 사건이나 결과가 발생할 가능성을 수치로 나타낸 것
 - 사건 A가 발생할 확률: $P(A)$
 - 확률은 0 이상 1 이하의 값을 가짐
 - 모든 가능한 사건의 확률을 합하면 1이 됨
- **독립사건과 확률:** 두 사건 A와 B가 독립사건이라는 것은 한 사건의 발생 여부가 다른 사건의 발생 가능성에 영향을 주지 않는다는 의미
 - **동시 발생 확률:** 사건 A와 B가 독립사건일 때, 두 사건이 동시에 발생할 확률 $P(A \cap B) = P(A) \times P(B)$
 - **조건부 확률과 독립사건:** 조건부 확률은 사건 B가 발생했다는 조건하에서 사건 A가 발생할 확률을 의미, $P(A | B)$
 - 사건 A와 B가 독립사건이라면, 사건 B의 발생 여부는 사건 A의 확률에 영향을 주지 않음
 - $P(A | B) = P(A)$

기초 통계 용어

- 확률변수(Random variable)
 - 표본 공간의 각 단위 사건에 실수 값을 부여하는 함수
 - 정의역이 표본공간, 치역이 실수값인 함수



예1) 동전 던지기: 동전을 한 번 던졌을 때 앞면이 나오면 1, 뒷면이 나오면 0으로 정의할 수 있다.

$$X = \begin{cases} 1, & \text{앞면} \\ 0, & \text{뒷면} \end{cases}$$

예2) 주사위 던지기: 주사위를 한 번 던졌을 때 나오는 눈의 수를 X 라고 하면,
 $X = 1, 2, 3, 4, 5, 6$



기초 통계 용어

- 확률변수(Random variable)

- 이산형 확률변수
- 연속형 확률변수

- 확률분포


- 확률변수가 가질 수 있는 각 값과 그 값이 발생할 확률의 관계를 나타낸 것
- 확률변수가 어떤 값을 얼마나 자주 또는 얼마나 높은 가능성으로 가지는지를 설명하는 분포



확률변수와 확률함수

- 주사위를 던져 나온 수를 확률변수 X 라고 할 때, 확률변수 X 와 확률 함수는?

주사위 눈과 확률 변수의 대응						
주사위 눈	1	2	3	4	5	6
확률 변수 X						



도수분포와 히스토그램

도수분포 Frequency Distribution

- 자료를 일정한 범위의 **계급구간**으로 나눈 뒤, 각 구간에 속하는 자료의 개수를 정리한 표이다.
- 자료의 전체적인 분포 형태를 파악하는 데 사용
- 자료가 어느 구간에 많이 또는 적게 분포하는지 확인 가능
- 연속형 자료나 관측값이 많은 자료를 요약할 때 유용

주요 용어

- **계급구간**: 자료를 나누는 일정한 범위
- **도수**: 각 계급구간에 속하는 자료의 개수
- **계급구간의 수**: 일반적으로 5개~15개 정도 사용
- **계급구간의 폭**:

$$\frac{\text{최댓값} - \text{최솟값}}{\text{계급구간의수}}$$

도수분포와 히스토그램

상대도수 Relative Frequency

- 전체 자료 중 특정 구간이 차지하는 비율을 의미
- 모든 상대도수의 합은 1
- 백분율로 표현하면 각 구간의 비중을 쉽게 비교할 수 있음
- 상대도수는 각 계급구간의 도수를 전체 자료의 수로 나눈 값

$$\text{상대도수} = \frac{\text{각계급구간의도수}}{\text{전체자료의수}}$$

계급구간	도수
0 ~ 5	8
6 ~ 10	9
11 ~ 15	4
16 ~ 20	3
21 ~ 25	1
합계	25

<도수 분포>

계급구간	상대도수
0 ~ 5	0.32
6 ~ 10	0.36
11 ~ 15	0.16
16 ~ 20	0.12
21 ~ 25	0.04
합계	1.00

<상대 분포>


도수분포와 히스토그램

히스토그램 Histogram

- 히스토그램은 도수분포 또는 상대도수분포를 막대그래프 형태로 나타낸 것
 - 가로축: 계급구간
 - 세로축: 도수 또는 상대도수
 - 각 막대의 높이: 해당 계급구간에 속하는 자료의 수 또는 비율

누적도수분포 Cumulative Frequency Distribution

- 누적도수분포는 각 계급구간의 도수를 이전 구간부터 차례대로 더해 정리한 분포



도수, 누적도수, 누적상대도수 표

계급구간 (대기시간)	도수	상대도수	누적도수	누적상대도수
0 ~ 5	8	0.32	8	0.32
6 ~ 10	9	0.36	17	0.68
11 ~ 15	4	0.16	21	0.84
16 ~ 20	3	0.12	24	0.96
21 ~ 25	1	0.04	25	1.00
합계	25	1.00	25	1.00

도수분포와 히스토그램

도수분포 형태로만 자료가 주어지는 경우 평균, 분산 및 표준편차 계산

1 내년도 경제성장률 전망

전망치(%)	도수
0 ~ 2	4
2 ~ 4	12
4 ~ 6	8
6 ~ 8	6
합계	30

해석

- 전망치(%)는 계급구간으로 주어져 있습니다.
- 도수는 각 구간에 속하는 자료의 개수입니다.
- 전체 자료 수는 30개입니다.

2 평균과 분산 및 표준편차

평균
($\bar{X}$)

$$\bar{X} = \frac{1 \times 4 + 3 \times 12 + 5 \times 8 + 7 \times 6}{30} = 4.07$$

분산
(s^2)

$$s^2 = \frac{(1 - 4.07)^2 \times 4 + (3 - 4.07)^2 \times 12 + (5 - 4.07)^2 \times 8 + (7 - 4.07)^2 \times 6}{30 - 1} = 3.79$$

표준편차
(s)

$$s = \sqrt{3.79} = 1.95$$

계산 원리

- 각 계급구간의 중앙값을 대표값으로 사용합니다.
- 중앙값: 1, 3, 5, 7
- 분산 계산 시 분모는 $n-1$ 을 사용합니다.

Contingency Table


- 두 범주형 변수에 대한 관측값을 요약하고 해석하기 위한 표 형태의 자료 정리 방법
- 두 변수가 모두 범주형 변수일 때 사용, 도수분포표를 2차원 형태로 확장한 형태
- 한 변수의 범주는 행(Row)에, 다른 변수의 범주는 열(Column)에 배치
- 각 셀(Cell)에는 두 범주가 동시에 나타난 관측값의 수를 기록
- 두 변수 간의 관계나 분포를 비교·분석할 때 활용

예시 성별에 따른 찬성·반대 의견 조사 결과

성별	찬성	반대	합계
남자	10	21	31
여자	15	24	39
합계	25	45	70


분할표

예시 1 막대그래프로 나타낸 분할표



낮은 설탕 섭취 그룹은 '자주 운동'이 더 많고,
높은 설탕 섭취 그룹은 '드물게 운동'이 더 많습니다.

예시 2 버블 차트로 나타낸 분할표



- **이산형 확률분포**

- 베르누이 확률분포(Bernoulli distribution)
- 이항분포(Binomial distribution)
- 기하분포(Geometric distribution)
- 포아송분포(Poisson distribution)

- **연속형 확률분포**

- 균등분포(Uniform distribution)
- 정규분포(Normal distribution)
- 지수분포(Exponential distribution)
- t-분포(t-distribution)
- 카이제곱분포(chi-square distribution)
- F-분포(F-distribution)

- 이산형 확률분포 – 베르누이 확률분포

- 베르누이 시행 Bernoulli Trial

베르누이 시행은 결과가 두 가지 경우만 가능한 확률 실험 (성공(Success), 실패(Failure))
한 번의 시행에서 결과가 오직 두 가지 중 하나로만 나타나는 실험을 의미

- 베르누이 확률변수: 베르누이 시행의 결과를 숫자로 표현한 확률변수

$$X = \begin{cases} 1, & \text{시행 결과가 성공인 경우} \\ 0, & \text{시행 결과가 실패인 경우} \end{cases}$$


- 베르누이 분포 Bernoulli Distribution: 베르누이 확률변수 X 가 따르는 확률분포

성공 확률: p

실패 확률: $1 - p$

- 확률질량함수 Probability Mass Function

$$f(x) = p^x(1 - p)^{1-x}, \quad x = 0, 1$$



확률분포

- 이산형 확률분포 – 베르누이 확률분포, 평균과 분산
평균(Expected Value)

$$E(X) = \sum x P(X = x)$$

베르누이 확률변수는 0과 1만 가능하므로,

확률값을 대입하면,

따라서,

- 이산형 확률분포 – 베르누이 확률분포, 평균과 분산
분산(Variance)

$$\text{Var}(X) = E(X^2) - \{E(X)\}^2$$

(1) $E(X^2)$ 계산

$$E(X^2) =$$

베르누이 확률변수에서는 $X = 0$ 또는 1 만 가능하므로,

$$E(X^2) =$$

정리하면,

- 이산형 확률분포 – 베르누이 확률분포, 평균과 분산
분산(Variance)

$$\text{Var}(X) = E(X^2) - \{E(X)\}^2$$

(2)평균의 제곱 계산

앞에서 구한 평균은

$$E(X) =$$

이므로,

$$\{E(X)\}^2 =$$

(3)분산 계산

분산 공식에 대입하면,

$$\text{Var}(X) =$$

$$\text{Var}(X) =$$

- 이산형 확률분포 – 이항분포

- 이항확률변수는 성공확률이 p 로 일정한 베르누이 시행을 n 번 독립적으로 반복할 때, 성공한 횟수를 나타내는 확률변수

$$X \sim B(n, p)$$

n : 전체 시행 횟수

p : 각 시행에서의 성공확률

X : n 번 시행 중 성공한 횟수

- **이항분포 Binomial Distribution:** 이항확률변수 X 가 따르는 확률분포로 n 번의 독립적인 베르누이 시행에서 성공 횟수 X 의 확률분포를 의미

- 이항 확률함수

$$f(x) = \binom{n}{x} p^x (1-p)^{n-x}$$

$\binom{n}{x}$: n 번 중 성공이 x 번 나타나는 경우의 수

p^x : 성공이 x 번 발생할 확률

$(1-p)^{n-x}$: 실패가 $n-x$ 번 발생할 확률

확률분포

- 이산형 확률분포 – 이항분포, 평균과 분산

평균(Expected Value)

X 는 n 개의 베르누이 확률변수의 합으로 나타낼 수 있다.

$$X = X_1 + X_2 + \cdots + X_n$$

여기서 각 X_i 는 다음과 같은 베르누이 확률변수이다.

$$X_i = \begin{cases} 1, & i \text{ 번째 시행이 성공} \\ 0, & i \text{ 번째 시행이 실패} \end{cases}$$

각 X_i 는

$$X_i \sim \text{Bernoulli}(p)$$

확률분포

- 이산형 확률분포 – 이항분포, 평균과 분산

평균(Expected Value)

기댓값의 선형성에 의해,

$$E(X) = E(X_1 + X_2 + \cdots + X_n)$$

$$E(X) = E$$

베르누이 확률변수의 평균은

이므로,

따라서,

확률분포

- 이산형 확률분포 – 이항분포, 평균과 분산

분산(Variance)

시험들이 서로 독립이므로, 합의 분산은 각 분산의 합과 같다.

$$Var(X) = Var(X_1 + X_2 + \cdots + X_n)$$

$$Var(X) =$$

베르누이 확률변수의 분산은

$$Var(X_i) =$$

이므로,

$$Var(X) =$$

따라서,

$$Var(X) =$$

확률분포

• 이산형 확률분포 – 포아송

- 포아송 분포는 **일정한 시간, 공간, 구간 안에서 특정 사건이 발생하는 횟수**를 나타낼 때 사용하는 확률분포
- 주로 사건이 드물게 발생하지만, 일정한 평균 발생률을 가지고 반복적으로 관측되는 경우에 활용
- 포아송 확률변수 X 는 일정한 구간에서 발생하는 사건의 횟수를 의미
 $X = \text{일정 구간에서 발생한 사건의 수}$

포아송 분포의 확률함수

$$f(x) = P(X = x) = \frac{\mu^x e^{-\mu}}{x!}, x = 0, 1, 2, \dots$$


X : 일정 구간에서 발생한 사건의 수

x : 실제 발생 횟수

μ : 일정 구간에서의 평균 발생 횟수

e : 자연상수

$x!$: x 의 계승



- 이산형 확률분포 – 포아송

포아송 분포의 조건

- 사건은 일정한 평균 발생률을 가짐
- 사건은 서로 독립적으로 발생
- 매우 짧은 구간에서는 두 개 이상의 사건이 동시에 발생할 가능성이 매우 작음
- 발생 횟수는 0 이상의 정수값을 가짐

포아송 분포의 예시

- 은행 창구 방문 고객 수: 1시간 동안 은행에 오는 고객 수
- 콜센터 전화 수: 10분 동안 걸려오는 전화 수
- 도로의 교통사고 발생 횟수: 하루 동안 특정 교차로에서 발생하는 사고 수

확률분포

- 이산형 확률분포 – 포아송, 평균과 분산

평균(Expected Value)

$$E(X) = \sum_{x=0}^{\infty} x P(X = x)$$

포아송 확률함수를 대입하면,

$$E(X) =$$

$x = 0$ 일 때는 값이 0이므로 $x = 1$ 부터 시작

$$E(X) =$$

$x/x! = 1/(x-1)!$ 이므로,

$$E(X) =$$

$$E(X) =$$

확률분포

- 이산형 확률분포 – 포아송, 평균과 분산

평균(Expected Value)

여기서 $k = x - 1$ 로 치환하면,

$$E(X) =$$

지수함수의 전개식

을 이용하면,

!

따라서,

- 이산형 확률분포 – 포아송, 평균과 분산

분산(Variance)

직접 $E(X^2)$ 를 계산하기보다,
을 먼저 구하면 계산이 쉬워짐

$$\text{Var}(X) = E(X^2) - (E(X))^2$$

$$E[X(X-1)]$$

- 이산형 확률분포 – 포아송, 평균과 분산

분산(Variance)

(1) $E[X(X-1)]$ 계산

$$E[X(X-1)] = \sum_{x=0}^{\infty} x(x-1)P(X=x)$$

확률함수를 대입하면,

$$E[X(X-1)] = \sum_{x=2}^{\infty} x(x-1) \frac{\mu^x e^{-\mu}}{x!}$$
$$\frac{x(x-1)}{x!} = \frac{1}{(x-2)!}$$

이므로,

$$E[X(X-1)] = \sum_{x=2}^{\infty} \frac{\mu^x e^{-\mu}}{(x-2)!} = \mu^2 e^{-\mu} \sum_{x=2}^{\infty} \frac{\mu^{x-2}}{(x-2)!}$$

$k = x - 2$ 로 치환하면,

$$E[X(X-1)] = \mu^2 e^{-\mu} \sum_{k=0}^{\infty} \frac{\mu^k}{k!} = \mu^2 e^{-\mu} e^{\mu} = \mu^2$$

- 이산형 확률분포 – 포아송, 평균과 분산

분산(Variance)

(2) $E(X^2)$ 계산

$$X^2 = X(X - 1) + X$$

따라서,

$$E(X^2) = E[X(X - 1)] + E(X)$$

$$E(X^2) = \mu^2 + \mu$$

(3) 분산 계산

$$\text{Var}(X) = E(X^2) - (E(X))^2$$

$$\text{Var}(X) = (\mu^2 + \mu) - \mu^2$$

따라서,


$$\text{Var}(X) = \mu$$

확률분포

- 연속형 확률분포 - 균등분포

- 정해진 구간 안의 모든 값이 똑같은 가능성으로 나타나는 분포
- 예를 들어 0부터 10 사이에서 숫자 하나를 무작위로 고른다고 하면, 1이 나올 가능성과 7.5가 나올 가능성이 동일하다고 보는 것이 균등분포
- 확률변수 X 가 구간 $[a, b]$ 에서 균등분포를 따르면 $\rightarrow X \sim U(a, b)$
- 연속형 균등분포의 확률밀도함수

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{그 외} \end{cases}$$



• 연속형 확률분포 – 정규분포

- 정규분포는 연속확률분포 중 하나로, 우리 주변의 많은 자연적·사회적 현상에서 자주 나타나는 대표적인 확률분포
예) 사람들의 키, 시험 점수, 측정 오차, 제품의 무게 오차, 혈압, IQ 점수
→ 어떤 값들이 평균을 중심으로 몰려 있고 평균에서 멀어질수록 점점 적게 나타나는 경우
- 그래프의 가운데가 가장 높고 양쪽으로 갈수록 낮아지는 종 모양의 곡선이며, 평균을 기준으로 좌우가 대칭인 형태

특징

- 평균(mean), 중앙값(median), 최빈값(mode)이 모두 같은 위치
- 정규분포는 평균 μ 와 표준편차 σ 에 의해 모양이 결정
 - 평균 μ 는 분포의 중심 위치를 나타내며, 평균이 커지면 그래프 전체가 오른쪽으로 이동하고 평균이 작아지면 왼쪽으로 이동
 - 표준편차 σ 는 데이터가 평균 주변에 얼마나 퍼져 있는지를 나타냄. 표준편차가 작으면 값들이 평균 근처에 많이 모여 그래프가 좁고 뾰족해지며, 표준편차가 크면 값들이 넓게 퍼져 그래프가 낮고 완만해짐


확률분포

- 연속형 확률분포 - 정규분포

$$X \sim N(\mu, \sigma^2)$$

확률밀도함수


$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$



확률분포

• 연속형 확률분포 - 표준정규분포

- 표준정규분포는 평균이 0이고 분산이 1인 정규분포를 의미
- 일반적인 정규분포 $X \sim N(\mu, \sigma^2)$ 는 평균과 표준편차가 서로 다를 수 있기 때문에 직접 비교가 어려움
- 표준화 과정을 통해 $Z = \frac{X - \mu}{\sigma}$ 로 변환하면 평균이 0, 표준편차가 1인 표준정규분포 $Z \sim N(0, 1)$ 를 따르게 된다.
- Z-score는 어떤 관측값이 평균으로부터 표준편차 몇 개만큼 떨어져 있는지를 나타내며, 서로 다른 단위나 분포를 가진 자료도 같은 기준에서 비교할 수 있게 해줌
- 표준정규분포는 정규분포에서 특정 구간의 확률을 계산하거나, 관측값의 상대적 위치를 해석할 때 기본적으로 사용




확률분포

• 연속형 확률분포 - 지수분포

- 지수분포는 어떤 사건이 한 번 발생한 뒤, 다음 사건이 발생할 때까지 걸리는 시간을 나타내는 연속확률분포
 - 고객센터에 다음 전화가 올 때까지 걸리는 시간
 - 버스가 다음에 도착할 때까지 걸리는 시간
 - 웹사이트에 다음 방문자가 들어올 때까지 걸리는 시간

지수분포는 보통 다음과 같이 표현 (λ 는 단위 시간당 평균 사건 발생 횟수)

$$T \sim \text{Exp}(\lambda)$$



지수분포

모수 $\lambda (\lambda > 0)$ 를 갖는 지수분포의 확률밀도함수(PDF)는 다음과 같다.

$$f(t) = \begin{cases} \lambda e^{-\lambda t}, & t \geq 0 \\ 0, & t < 0 \end{cases}$$

- λ : 하자율(위험률) 또는 사건 발생률
- t : 시간 ($t \geq 0$)
- 기대값 $E(T) = 1/\lambda$
- 분산 $\text{Var}(T) = 1/\lambda^2$

- 연속형 확률분포 - 지수분포

지수분포의 확률밀도함수

$$f(t) = \lambda e^{-\lambda t}, t > 0$$

- T : 다음 사건이 발생할 때까지의 대기시간
- λ : 단위 시간당 평균 사건 발생률
- t : 대기시간

$$E(T) = \frac{1}{\lambda}, \quad Var(T) = \frac{1}{\lambda^2}$$

- 연속형 확률분포 - 지수분포

지수분포 활용 예시

확률변수 T = 다음 사건이 발생할 때까지 걸리는 시간

$$T \sim \text{Exp}(\lambda)$$

누적분포함수: 시간 t 이내에 사건이 발생할 확률을 계산

$$P(T \leq t) = 1 - e^{-\lambda t}$$

반대로, 시간 t 가 지나도 사건이 발생하지 않을 확률

$$P(T > t) = e^{-\lambda t}$$

예) 평균적으로 10분에 한 번 전화가 온다면 $\lambda = 0.1$

5분 안에 전화가 올 확률은

$$P(T \leq 5) = 1 - e^{-0.1 \times 5} = 1 - e^{-0.5} \approx 0.393$$

확률분포


• 연속형 확률분포 - 지수분포

지수분포 활용 예시

예) 평균적으로 10분에 한 번 전화가 온다면 $\lambda = 0.1$

5분 안에 전화가 올 확률은

$$P(T \leq 5) = 1 - e^{-0.1 \times 5} = 1 - e^{-0.5} \approx 0.393$$



기초 통계 용어 (2)


- **기술통계학 Descriptive Statistics**

- 기술통계학은 수집된 자료의 특징을 정리하고 요약하는 통계 방법
- 자료를 표, 그래프, 평균, 중앙값, 표준편차, 상관계수 등으로 표현하여 집단의 전반적인 성질을 파악
- 주어진 자료가 어떤 형태로 분포하는지, 중심은 어디에 있는지, 얼마나 흩어져 있는지를 설명하는 것이 목적
예) 한 학급 학생 30명의 시험 점수를 이용해 평균 점수, 최고점, 최저점, 점수 분포 그래프를 제시

- **추측통계학 Inferential Statistics**

- 모집단 전체를 직접 조사하기 어려울 때, 일부 표본을 이용하여 모집단의 특성을 추정하거나 판단하는 통계 방법
- 표본평균이나 표본비율을 이용해 모집단 평균, 모집단 비율 등을 추정하고, 어떤 주장이나 가설이 통계적으로 타당한지 검정
 - 추정 (Estimation): 표본을 이용하여 모집단의 특성치(평균, 표준편차, 비율 등)에 대한 추정값과 그 정확성을 제시
 - 검정 (Testing): 아직 검증되지 않은 어떤 주장을 통계적 방법으로 검증하는 것
- 표본에서 얻은 정보를 바탕으로 전체 집단에 대한 결론을 도출하는 것이 목적
예) 유권자 1,000명을 조사하여 전체 유권자의 특정 후보 지지율을 추정하는 것

기초 통계 용어 (2)




가설 검정

- 통계적 가설검정은 모집단의 특성에 대한 주장 또는 가설을 세우고 표본에서 얻은 정보를 이용해 가설이 옳은지를 판정하는 과정
- 귀무가설과 대립가설로 구분
 - 귀무가설(Null hypothesis):** 모집단이 어떠한 특징을 지닐 것으로 여겨지는 가설로서 일반적으로 "차이가 없다", "같다" 기호를 사용하여 나타낼 수 있는 가설로 흔히 H_0 로 나타냄
 - 대립가설(Alternative hypothesis):** 귀무가설에 반대되는 가설로 귀무가설이 틀렸다가 판단될 경우 채택되는 가설로 H_1 로 나타냄

상황	귀무가설 (H_0)	대립가설 (H_1)
신약 효과 검정	신약은 기존 약보다 효과가 없다.	신약은 기존 약보다 효과가 있다.
평균 점수 비교	A반과 B반의 평균 점수는 차이가 없다.	A반과 B반의 평균 점수는 차이가 있다.
고객 만족도 개선 여부	서비스 개선 전후 고객 만족도는 차이가 없다.	서비스 개선 후 고객 만족도가 개선 전보다 높아졌다.

가설 검정

	귀무가설이 참 (TRUE) H_0 가 참이다	귀무가설이 거짓 (FALSE) H_0 가 거짓이다
귀무가설을 기각 (Reject H_0) (데이터가 H_0 와 일치하지 않는다고 판단)	 제1종 오류 (Type I Error) (거짓양성, False Positive) 귀무가설이 참인데, 귀무가설을 기각하는 오류 (α 오류 수준으로 통제)	 올바른 판단 (Correct Decision) (참양성, True Positive) 귀무가설이 거짓인데, 귀무가설을 올바르게 기각
귀무가설을 기각하지 않음 (Fail to reject H_0) (데이터가 H_0 와 일치한다고 판단)	 올바른 판단 (Correct Decision) (참음성, True Negative) 귀무가설이 참인데, 귀무가설을 올바르게 기각하지 않음	 제2종 오류 (Type II Error) (거짓음성, False Negative) 귀무가설이 거짓인데, 귀무가설을 기각하지 않는 오류 (β 오류, 검정력(power)과 관련)



가설 검정

가설검정 예시

- 신약을 복용한 집단과 복용하지 않은 집단의 평균 혈압 감소 효과에는 차이가 있는지 데이터 분석을 통해 차이가 있는지를 검정
 - 귀무가설 H_0 :두 집단의 평균 혈압 감소량은 같다.
 - 대립가설 H_1 :두 집단의 평균 혈압 감소량은 다르다.
- 유의수준을 0.05로 설정했을 때 p-value가 0.021로 나타났으므로, $p\text{-value} < 0.05$ 에 따라 귀무가설을 기각하고 두 집단의 평균 혈압 감소량에는 통계적으로 유의한 차이가 있다고 판단

가설 검정

- 유의수준(Significance level, α)

- 귀무가설이 실제로 참인데도, 표본 결과만 보고 귀무가설을 잘못 기각할 수 있는 최대 허용 확률을 의미
- 기호로는 보통 α 로 나타내며, 대표적으로 0.05 또는 0.01을 사용

예) 유의수준 $\alpha = 0.05$: 귀무가설이 맞는데도 이를 기각하는 오류를 최대 5%까지 허용 → 제1종 오류(Type I error)

- 유의수준은 연구자가 "어느 정도까지 우연한 결과를 감수하고 결론을 내릴 것인가"를 정하는 기준
- 가설검정에서는 계산된 p-value가 유의수준보다 작으면 귀무가설을 기각, 크거나 같다면 기각하지 않음

$$p\text{-value} < \alpha \Rightarrow \text{귀무가설 } H_0 \text{ 기각}$$

$$p\text{-value} \geq \alpha \Rightarrow \text{귀무가설 } H_0 \text{ 기각하지 않음}$$

가설 검정


- **기각역 Rejection Region**

- 귀무가설을 기각하기로 결정하는 검정통계량의 범위
- 귀무가설이 참이라고 가정했을 때, 매우 드물게 나타나는 극단적인 값들이 여기에 해당
- 유의수준 α 는 기각역의 크기를 결정한다.
- 예를 들어 $\alpha = 0.05$ 라면, 귀무가설이 참일 때도 우연히 발생할 수 있는 극단적인 5% 영역을 기각역으로 설정
- 검정통계량이 기각역에 들어가면 결과를 우연이라고 보기 어렵다고 판단하여 귀무가설을 기각


- **임계값 Critical Value**

- 임계값은 기각역과 채택역을 나누는 기준값
- 검정통계량이 이 값을 넘거나 이 값보다 작아지면 기각역에 해당

가설 검정



가설 검정



가설 검정

- **P-value**

- 귀무가설이 참이라고 가정했을 때, 현재 관찰된 검정통계량만큼 또는 그보다 더 극단적인 결과가 나타날 확률
- 관찰된 표본 결과가 귀무가설과 얼마나 잘 맞는지를 판단하는 기준
- P-value가 작다는 것은, 귀무가설이 참이라면 현재와 같은 결과가 나타날 가능성이 낮다는 의미
→ 귀무가설을 기각할 근거
- 반대로 P-value가 크다는 것은, 현재의 결과가 귀무가설하에서도 충분히 나타날 수 있다는 의미

가설 검정



문제 상황

신약을 복용한 집단과 복용하지 않은 집단의 평균 혈압 감소 효과에는 차이가 있는지 데이터 분석을 통해 차이가 있는지를 검정

귀무가설 (H_0)

두 집단의 평균 혈압 감소량은 같다.

$$\mu_1 = \mu_2$$

대립가설 (H_1)


두 집단의 평균 혈압 감소량은 다르다.

$$\mu_1 \neq \mu_2$$

개념 설명

- 귀무가설이 참일 때, 검정통계량은 중심(0) 부근에 위치할 가능성이 높다.
- 극단적인 값이 관측되면 귀무가설이 거짓일 가능성이 있다고 판단한다.

귀무가설 H_0 가 참일 때의 분포
(표준정규분포 가정)



Type I Error (제1종 오류)

귀무가설이 참인데,
귀무가설을 기각하는 오류

발생 확률 = 유의수준 $\alpha = 0.05$

가설 검정

가설검정의 오류

- 가설검정에서는 귀무가설 H_0 이 실제로 참인지 거짓인지 알 수 없는 상태에서, 표본자료를 바탕으로 귀무가설 기각여부를 결정
- 이 과정에서 잘못된 판단을 할 수 있는데, 대표적으로 제1종 오류와 제2종 오류가 있음

- 제1종 오류 Type I Error: 귀무가설이 실제로 참인데도 귀무가설을 기각하는 오류


$$\alpha = P(\text{귀무가설 기각} \mid \text{귀무가설 참})$$

- 제2종 오류 Type II Error: 귀무가설이 실제로 거짓인데도 귀무가설을 기각하지 못하는 오류

$$\beta = P(\text{귀무가설 기각하지 않음} \mid \text{귀무가설 거짓})$$

가설 검정

가설검정의 오류



가설 검정

가설검정의 오류

Type I Error




Type II Error



가설 검정

가설검정 절차




통계 중요 개념 (1)

중심 극한 정리

- 중심극한정리는 모집단의 분포가 정규분포가 아니더라도, 표본의 크기가 충분히 크면 표본평균의 분포가 정규분포에 가까워진다는 정리
- 원래 자료가 한쪽으로 치우친 분포이거나 불규칙한 분포를 가지더라도, 같은 크기의 표본을 여러 번 추출하여 각각의 표본평균을 구하면 그 표본평균들은 평균을 중심으로 종 모양의 정규분포 형태를 보이게 됨

표본크기(n)가 커질수록 표본평균($\bar{X}$)의 분포는 정규분포에 가까워진다



통계 중요 개념 (2)

상관관계와 인과관계

- **상관관계**: 두 변수가 함께 움직이는 관계를 의미
- **인과관계**는 한 변수가 다른 변수의 원인이 되는 관계를 의미
 - 한 변수가 증가할 때 다른 변수도 증가하거나 감소하는 경향이 있으면 두 변수 사이에 상관관계가 있다고 봄
 - 인과관계는 원인 변수의 변화가 결과 변수의 변화를 직접적으로 만들어내는 경우
 - 모든 인과관계는 상관관계를 포함하지만, 모든 상관관계가 인과관계를 의미하지는 않음
 - 두 변수 사이에 상관관계가 있더라도 실제로는 제3의 변수, 즉 교락변수(Confounder)가 두 변수 모두에 영향을 주고 있을 수 있음

예) 아이스크림 판매량과 물놀이 사고 건수가 함께 증가

→ 아이스크림이 사고를 유발한다고 볼 수는 없음

→ 실제로는 **기온 상승**이라는 교락변수가 아이스크림 판매량과 물놀이 활동을 동시에 증가시켰을 가능성이 크다.

- 따라서 상관관계를 인과관계로 해석하기 위해서는 단순한 수치적 관계뿐만 아니라 시간적 선후관계, 이론적 근거, 실험 또는 통제된 분석이 필요

통계 중요 개념 (3)

Bootstrap


- Bootstrap은 하나의 표본에서 다시 표본을 반복적으로 뽑아 통계량의 변동성을 추정하는 방법
- Bradley Efron이 1979년에 제안한 방법으로, 원자료의 분포를 정확히 알기 어렵거나 이론적인 표준오차 계산이 복잡할 때 유용하게 사용
- Bootstrap의 핵심은 복원추출으로 주어진 표본에서 관측값을 하나 뽑은 뒤 다시 넣고, 또 뽑는 과정을 반복하여 원래 표본과 같은 크기의 새로운 표본을 만들 $\rightarrow$ bootstrap sample이라고 한다.



통계 중요 개념 (3)-2

Bootstrap Aggregating (Bagging)

- Bagging은 여러 개의 데이터 샘플을 복원추출(bootstrap)하여 각각의 모델을 학습시키고, 그 결과를 결합하는 앙상블 기법
- 각 모델이 서로 다른 데이터를 기반으로 학습하기 때문에 모델의 분산(variance)을 줄여 과적합을 완화
- 대표적인 예시로 Random Forest 가 있으며, 여러 결정트리의 예측 결과를 평균 또는 투표 방식으로 결합



통계 중요 개념 (4)

Imputation

- 데이터에 빠져 있는 값, 즉 결측치를 분석 가능한 값으로 채워 넣는 과정
- 결측치가 많거나 특정 패턴으로 발생하면 분석 결과에 편향이 생길 수 있으므로 적절한 처리가 필요
- 가장 기본적인 방법은 결측치를 평균값, 중앙값, 최빈값 등 대표값으로 대체하는 것
- 수치형 변수는 평균값이나 중앙값을 사용할 수 있고, 범주형 변수는 최빈값을 사용
- 보다 정교한 방법으로는 회귀모델을 이용한 예측값 대체, kNN을 이용한 유사 데이터 기반 대체 등이 있음
- 이 방법들은 다른 변수들과의 관계를 활용하여 결측치를 추정

	col1	col2	col3	col4	col5			col1	col2	col3	col4	col5	
0	2	5.0	3.0	6	NaN	mean()		0	2.0	5.0	3.0	6.0	7.0
1	9	NaN	9.0	0	7.0			1	9.0	11.0	9.0	0.0	7.0
2	19	17.0	NaN	9	NaN			2	19.0	17.0	6.0	9.0	7.0