

Machine Learning (3)

Hunsik Shin

Department of Industrial and Data Engineering

{hunsik.shin}@hongik.ac.kr


Introduction to Clustering

Clustering

군집화(Clustering)는 데이터 안에서 서로 비슷한 특성을 가진 객체들을 하나의 그룹 혹은 군집(cluster)으로 묶는 기법

군집화에서는 각 객체가 어떤 그룹에 속해야 하는지에 대한 정답 레이블(y)이 존재하지 않기 때문에, 비지도 학습(unsupervised learning) 알고리즘

군집화 알고리즘은 주로 객체 간 유사도(similarity) 또는 거리(distance) 정보를 활용
서로 유사한 객체는 같은 군집, 서로 다른 객체는 다른 군집으로 분류




Introduction to Clustering

Clustering

좋은 군집의 기준은 여러 가지가 있지만, 공통적으로 군집 내부의 데이터들은 서로 유사하고(intra-cluster similarity), 군집 간의 객체들은 서로 이질적(inter-cluster dissimilarity)이어야 함

→ 군집 내 거리(intra-cluster distance)는 작고 군집 간 거리(inter-cluster distance)는 멀어야 함

군집화 알고리즘을 적용하기 전에, 데이터 표현(Representation)과 데이터 간의 유사도/거리 정의가 중요



k-means clustering

- 비지도 학습의 대표적인 분석 방법으로 Clustering 방법들 중 가장 기본이 되는 기법
- 주어진 데이터를 유사한 K개의 군집으로 묶는 알고리즘
- 군집을 나누는 방법에 따라 여러 종류로 구분됨.
- 데이터에 대한 이해 단계인 (EDA, exploratory data analysis)단계에서 부터 고객 세그멘테이션, 이미지 분할 등에 광범위하게 적용 가능
- 모집단 또는 범주에 대한 사전 정보가 없을 때
 - 주어진 관측값들 사이의 거리 측정
 - 유사성을 이용하여 분석

k-means clustering

n 개의 데이터가 주어졌을 때, 두 데이터 x_i 와 x_j 사이의 유사성을 측정하기 위해 Cosine, Euclidean, 혹은 임의로 정의한 거리 $d(x_i, x_j)$ 를 사용

모든 데이터는 k 개의 군집으로 나누어진다고 가정하며, 각 군집은 하나의 대표값 벡터(centroid)를 가짐

- 알고리즘:


군집의 대표값 벡터를 초기화

(1) 군집화 과정에서 각 데이터 점을 가장 가까운 대표값 벡터에 재할당(reassign)

(2) 이후 각 군집에 속한 데이터들의 평균을 다시 계산하여 대표값 벡터를 업데이트(update)하는 과정을 반복




k -means clustering



1. Initialize

$k=3$ 이라 가정하면 3개의 점을 임의로 선택

k -means clustering



1. Initialize


$k=3$ 이라 가정하면 3개의 점을 임의로 선택

2. Assign (epoch=0)

모든 점을 k 개의 centroid 중 가장 가까운 점의 색깔(label)로 할당

k 개의 centroids에 의하여 분할된 공간의 경계면으로, Voronoi partition, Voronoi diagram이라 부름

k -means clustering



데이터에는 존재하지 않는 가상의
centroids

1. Initialize

$k=3$ 이라 가정하면 3개의 점을 임의로 선택

2. Assign (epoch=0)

모든 점을 k 개의 centroid 중 가장 가까운 점의 색깔(label)로 할당

3. Update centroid (epoch=0)

같은 색깔(label) 점들의 평균값을 가상의 centroids로 설정

k -means clustering



1. Initialize

$k=3$ 이라 가정하면 3개의 점을 임의로 선택

2. Assign (epoch=1)

모든 점을 업데이트 된 centroids 중 가장 가까운 점으로 할당

k -means clustering



1. Initialize

$k=3$ 이라 가정하면 3개의 점을 임의로 선택

2. Assign (epoch=1)




모든 점을 업데이트 된 centroids 중 가장 가까운 점으로 할당

3. Update centroid (epoch=1)

색깔이 바뀐 점이 있기 때문에 Centroid를 다시 업데이트

알고리즘이 종료 될 때까지 2, 3을 반복

k -means clustering




1. Initialize

$k=3$ 이라 가정하면 3개의 점을 임의로 선택

2. Assign (epoch=2)

모든 점을 가장 가까운 centroids로 할당하여도 색깔이 변하지 않으므로 알고리즘 종료

k -means clustering



출처: https://commons.m.wikimedia.org/wiki/File:K-means_convergence.gif

k-means clustering

k-means clustering 특징

- *k*-means은 local optimal을 찾는 heuristic 알고리즘 (매우 빠른 알고리즘으로 널리 사용)
- 계산 복잡도가 비교적 낮아, 전체 복잡도는 대략 $O(n \cdot i \cdot k)$ 로 표현 (n =데이터 수, i =반복(iteration) 수, k =군집 수)
- 모든 데이터 간 거리를 계산하는 pairwise distance matrix가 필요 없음 → 대규모 데이터셋에 특히 적합
- 데이터 row 단위로 업데이트가 가능하므로, mini-batch 학습이나 분산 환경(distributed setting)에서 구현 가능

k-means clustering

Magnitude of vector

- p - norm: 벡터의 크기를 정의하는 방식

- $|X|_p = \sqrt[p]{|X_1|^p + \dots + |X_q|^p}$

- 예시

2-norm: $|(3, 0, 4)|_{p=2} = \sqrt{|3|^2 + |0|^2 + |4|^2} = 5$

1-norm: $|(3, 0, -4)|_{p=1} = \sqrt[1]{|3|^1 + |0|^1 + |-4|^1} = 7$


0-norm: $|(3, 0, 4)|_{p=0} = |3|^0 + |4|^0 = 2$ ($\rightarrow$ # of non-zero elements)

Inner product


- 내적은 두 벡터 간의 관계를 정의하는 방식
- $(3, 0, 4)^T(1, 2, 3) = 3 * 1 + 0 * 2 + 4 * 3 = 3 + 0 + 12 = 15$

k-means clustering


Euclidean




Manhattan




Minkowski



Chebychev



Cosine Similarity



Hamming



k-means clustering

Spherical *k*-means

- Cosine similarity를 거리로 사용하는 *k*-means
- 학습 방법은 앞서 설명한 방식과 동일, 거리 측정 기준만 변경 (거리 기준 변경으로도 결과가 확연히 달라짐)
- scikit-learn 라이브러리 내 *k*-means 알고리즘의 거리 metric은 Euclidean으로 고정되어 있음

k-means clustering

Euclidean Distance

- 두 벡터의 차이의 2 - norm
- $eut((3, 0, 4), (1, 2, 3)) = ((3 - 1)^2 + (0 - 2)^2 + (4 - 3)^2)^{\frac{1}{2}} = (4 + 4 + 1)^{\frac{1}{2}} = 3$

Cosine Similarity

- 두 벡터 간의 거리를 유닛 벡터 간의 내적으로 정의
- $cos(u, v) = \frac{u \cdot v}{|u|_2 \cdot |v|_2} = \left(\frac{u}{|u|_2}\right) \cdot \left(\frac{v}{|v|_2}\right)$
- $cos((3, 0, 4), (4, 3, 0)) = \frac{12}{5 \times 5} = 0.48$

- 유닛 벡터의 Euclidean 거리의 순서는 Cosine 유사도 순서 반대

$$\begin{aligned} & |u - v|_2^2 \\ &= (u - v)^T (u - v) \\ &= |u|_2^2 - 2 \cdot u \cdot v + |v|_2^2 \\ &= 2(1 - u \cdot v) \\ &= 2(1 - cos(u, v)) \end{aligned}$$

k -means clustering

Limitations


1. Initial points 에 따라 군집의 모양이 달라짐
2. 적절한 군집의 개수 정의 필요
3. 노이즈 데이터에 민감함

k -means clustering


Limitations

1. Initial points 에 따라 군집의 모양이 달라짐

- k -means 는 initial points 만 잘 뽑아도 수렴이 빠르다고 알려져 있으며,
 - 사실, 최악의 initialization 만 아니면 수렴은 원래 빠릅니다.
 - 특정 지역에 initial points 가 모여있지만 않아도 됩니다.



Ideal initialization



Worst initialization

k-means clustering

Limitations

1. Initial points 에 따라 군집의 모양이 달라짐

→ 좋은 initial points를 찾기 위해 k-means++ 사용

→ 순차적으로 기존의 centroid에서 멀리 떨어진 점을 새로운 centroid로 선정

1. Select a point c_0 randomly

2. Select next point c_t with prob. $\frac{d(x)^2}{\sum_{x \in D} d(x)^2}$

$d(x)^2$: minimal distance between all points and already chosen points

3. Repeat step 2 until choosing k points

[scikit-learn 구현 내용]: `init='k-means++'`

`sklearn.cluster.KMeans`

```
class sklearn.cluster.KMeans(n_clusters=8, init='k-means++', n_init=10, max_iter=300, tol=0.0001,
precompute_distances='auto', verbose=0, random_state=None, copy_x=True, n_jobs=1, algorithm='auto')
```

[source]

k-means clustering

Limitations

2. 적절한 군집의 개수 정의 필요

- 군집의 개수 k 는 사용자가 직접 설정해야하는 hyper-parameter
- Silhouette score을 기반으로 군집화 품질의 척도를 계산

$$s(x) = \frac{b - a}{\max(a, b)}, \quad s(X) = \text{mean}(s(x))$$

a : mean distance between a sample and all other points in the same class

b : mean distance between a sample and all other points in the next nearest class

- $s \approx 1$: 군집 내부에 가깝고, 다른 군집과 멀다 → 군집화 잘 됨
- $s \approx 0$: 군집간 경계에 위치
- $s < 0$: 잘못된 군집, 다른 군집과 가깝고 군집 내부에서는 멀다


k -means clustering

Limitations

2. 적절한 군집의 개수 정의 필요

- 군집의 개수 k 는 사용자가 직접 설정해야하는 hyper-parameter
- Silhouette score을 기반으로 군집화 품질의 척도를 계산

Silhouette analysis for KMeans clustering on sample data with $n_clusters = 3$




k -means clustering

Limitations

2. 적절한 군집의 개수 정의 필요

- 군집의 개수 k 는 사용자가 직접 설정해야하는 hyper-parameter
- Silhouette score을 기반으로 군집화 품질의 척도를 계산

Silhouette analysis for KMeans clustering on sample data with $n_clusters = 4$





k -means clustering

Limitations

2. 적절한 군집의 개수 정의 필요

- 군집의 개수 k 는 사용자가 직접 설정해야하는 hyper-parameter
- Silhouette score을 기반으로 군집화 품질의 척도를 계산

Silhouette analysis for KMeans clustering on sample data with $n_clusters = 5$




k -means clustering

Limitations

3. 노이즈 데이터에 민감함

모든 점을 반드시 한 개 이상의 군집으로 assign 하기 때문에, 일단 가장 가까운 군집에 할당되어 centroid 를 크게 움직임




k -means clustering

Limitations

3. 노이즈 데이터에 민감함

모든 점을 반드시 한 개 이상의 군집으로 assign 하기 때문에, 일단 가장 가까운 군집에 할당되어 centroid 를 크게 움직임


→ 사전에 데이터의 노이즈를 미리 제거




k -means clustering

Limitations

4. 원형(spherical)이 아닌 군집을 찾는다는 적절하지 않음.



Original Points



K-means (2 Clusters)

Association Analysis

월마트(Walmart) 사례

- 90년대 중반, 매주 수요일 저녁마다 기저귀와 맥주의 매출이 함께 높아지는 현상 발견.
- 담당자가 맥주와 기저귀 진열대를 일부러 가까운 곳에 붙여 놓았더니 두 제품의 매출이 전날보다 5배 증가.
- 전혀 관련성이 없는 맥주와 기저귀의 연결고리를 알게 됨으로써 마케팅 전략을 새롭게 구성하여 기업의 매출 향상의 중요한 도구가 될 수 있음.



출처: [https:// lifeindigital.org/](https://lifeindigital.org/)

Association Analysis

연관성 분석

- 데이터 내부에 존재하는 연관성, 항목 간의 상호 관계 혹은 종속 관계를 찾아내는 분석
- 하나의 거래나 사건에 포함되어 있는 항목들의 경향을 파악해서 상호연관성을 발견
- 어떤 개인이나 그룹에 의해 수행된 활동들 중에서 함께 발생하는(co-occurrence) 것들의 관계를 찾아내는 데이터 분석

예) 고객이 구매한 장바구니를 분석하여 거래되는 상품들의 연관성(규칙)을 발견, 분석

- 관련 상품끼리의 묶음 상품, 어떤 상품을 사기 위해 가는 동선에 관련 상품을 진열.
- 누가 어떤 상품을 구매할 것인지를 예측, 이를 통한 매출의 극대화
- 장바구니 분석(Market basket analysis) 이라고도 함.

Association Analysis


연관성 분석 활용

- 유통업 : 고객들이 함께 구매할 상품을 제안할 수 있음
- 호텔/숙박업 : 고객들이 특정 서비스를 받은 후 어떤 서비스를 다음으로 원하는지 선제안 할 수 있음
- 금융사 : 기존 금융 서비스 내역을 통해 대출 같은 특정 서비스를 받을 가능성이 높은 고객을 발굴할 수 있음
- 보험사 : 정상적인 청구 패턴과 다른 패턴을 보이는 고객을 찾아 추가 조사 실시할 수 있음



Association Analysis

연관성 분석 활용



Association Analysis

연관성 분석 활용

트랜잭션데이터 (transaction data)

연관
association



주문번호	라면	계란	식빵	우유	햄	...
1	O	O	X	X	O	...
2	O	O	X	X	X	...
3	O	O	X	X	X	...
4	X	X	O	O	X	...
...	...	...	...	...	...	...

Association Analysis

연관성 분석 활용

- 연관성 분석을 위해서는 **연관 규칙 Association Rule**을 찾아내야 함.
 - 연관규칙: 특정 사건이 발생하였을 때 함께 발생하는 또 다른 사건의 규칙.
- 연관규칙을 알기 위해서는
 - 사건들이 여러 개 있어야 하며,
 - 사건들 중 공통적으로 일어나는 사건들을 조합하여 하나의 규칙을 완성
 - 여러 개의 항목집합들 중에서 공통적으로 자주 발생하는 빈발 항목집합(Frequent itemset) 찾기
 - 이러한 항목들을 통해 만든 규칙을 빈발 패턴(Frequent pattern)이라고 함

Association Analysis

연관성 규칙


- A라는 상품과 B라는 상품이 서로 연관성이 있다고 하면 $A \rightarrow B$ 라고 하는 연관 규칙 생성.

- {조건} $\rightarrow$ {결과}

예) 품목 A와 품목 B를 구매한 고객은 품목 C를 구매한다 :

(품목 A) & (품목 B) $\rightarrow$ (품목 C)

- 상품의 수가 증가할 수록 연관 규칙도 증가하게 됨. 그 중 과연 어떤 연관 규칙이 가장 크리티컬하게 사용될 수 있는지 평가가 필요함.



[Source: 데이터마이닝, 장남식 외, 1999]

Association Analysis

연관성 규칙

- 연관 규칙 평가 기준 : 지지도(support), 신뢰도(confidence), 향상도(lift)
- 규칙이라는 특성 상 많이 일어나지 않는 희박한 항목에 대해서는 그 규칙을 일반화하거나 신뢰할 수 없다는 단점
- 연관성을 일반화하거나 신뢰할 수 있는 판단 기준이 필요
- 연관 규칙의 유용성과 효율성 입증 기준

Association Analysis

연관성 규칙 평가 - 지지도(Support)

- 전체거래(transaction)중 연관성 규칙을 구성하는 항목들(조건과 결과항목)이 포함된 거래의 비율을 의미
- 전체 거래항목 중 **상품 A와 상품 B를 동시에 포함하여 거래하는 비율**
- $A \rightarrow B$ 라고 하는 규칙이 전체 거래 중 차지하는 비율을 통해 해당 연관 규칙이 얼마나 의미가 있는 규칙인지를 확인
- **지지도 = $P(A \cap B)$** : A와 B가 동시에 포함된 거래 수 / 전체 거래 수
- 어느 정도 지지도가 있는 항목들 중에서 연관성 규칙을 알아보는 것이 바람직

Association Analysis

연관성 규칙 평가 - 신뢰도(Confidence)

- 조건이 발생했을 때 결과가 동시에 일어날 확률, 신뢰도가 1에 가까울수록 의미있는 연관성을 가지고 있다고 할 수 있음
- 상품 A를 포함하는 거래 중 A와 B가 동시에 거래되는 비중
- 상품 A를 구매 했을 때 상품 B를 구매할 확률이 어느정도 되는지를 확인
- $\text{신뢰도} = P(B|A) = P(A \cap B) / P(A) = \text{A와 B가 동시에 포함된 거래 수} / \text{A가 포함된 거래 수}$

Association Analysis

연관성 규칙 평가- 향상도(Lift)

- 상품 A의 거래 중 항목 B가 포함된 거래의 비율 / 전체 상품 거래 중 상품 B가 거래된 비율
- A가 주어지지 않았을 때 B의 확률 대비 A가 주어졌을 때 B의 확률 증가 비율

- 향상도 = $\frac{P(A \cap B)}{P(A) * P(B)} = \frac{P(B|A)}{P(B)}$

→ A와 B가 동시에 일어날 확률(지지도) / A, B가 독립된 사건일 때 A,B가 동시에 일어날 확률

- 향상도 = 1 : 조건과 결과는 우연에 의한 관계. 품목 A와 B사이에 아무런 관계가 상호 관계가 없다.
- 향상도 > 1 : 연관성이 높다. 우연이 아닌 의미있는 관계.

Association Analysis

연관성 규칙 예제 – 지지도, 신뢰도, 향상도 계산

- 거래내역 데이터를 통한 구매 행렬 계산
- 어느 대형 마트의 거래 내역

고객 번호	품목
1	삼겹살, 상추
2	삼겹살, 상추, 사이다
3	삼겹살, 깻잎
4	닭고기, 샤워 타올
5	닭고기, 콜라, 사이다

- 거래 내역을 기반으로 만든 구매 행렬

	삼겹살	상추	사이다	깻잎	닭고기	샤워 타올	콜라
삼겹살	3	2	1	1	0	0	0
상추	2	2	1	0	0	0	0
사이다	1	1	2	0	1	0	1
깻잎	1	0	0	1	0	0	0
닭고기	1	0	1	0	2	1	1
샤워 타올	0	0	0	0	1	1	0
콜라	0	0	1	0	1	0	1

출처: <https://zephyrus1111.tistory.com/119>

Association Analysis

연관성 규칙 예제 – 지지도, 신뢰도, 향상도 계산

지지도 : A와 B를 동시에 포함하는 비율이 높아야 한다.

“A이면 B이다.” 라는 규칙이 지지받기 위해서는 실제로 A, B를 동시에 포함하는 비율 $P(A \cap B)$ 값이 커야 함을 의미. 이러한 의미에서 $P(A \cap B)$ 를 지지도라고 함.

고객 번호	품목
1	삼겹살, 상추
2	삼겹살, 상추, 사이다
3	삼겹살, 깻잎
4	닭고기, 샤워 타올
5	닭고기, 콜라, 사이다

예)

- 사이다와 상추를 동시에 구입하는 거래는 5건 중 1건 뿐이다.
- 따라서, “상추를 사는 사람은 사이다도 구입한다”라는 규칙은 지지받기에는 발생 횟수가 충분하지 않다.
- “A이면 B이다” 라는 규칙이 지지받기 위해서는 실제로 A, B를 동시에 포함하는 비율이 높아야 한다는 것.

Association Analysis

연관성 규칙 예제 – 지지도, 신뢰도, 향상도 계산

신뢰도: A를 포함하는 거래 내역 중, B가 포함된 비율이 높아야 한다

“A이면 B이다.” 라는 규칙이 지지받기 위해서는 실제로 A, B를 동시에 포함하는 비율 $P(A \cap B)$ 값이 커야 함을 의미. 이러한 의미에서 $P(A \cap B)$ 를 지지도라고 함.

고객 번호	품목
1	삼겹살, 상추
2	삼겹살, 상추, 사이다
3	삼겹살, 깻잎
4	닭고기, 샤워 타올
5	닭고기, 콜라, 사이다

예)

-“삼겹살을 사는 사람은 상추도 구입한다” 라는 규칙의 신뢰도 : $P(\text{상추}|\text{삼겹살}) = \frac{\frac{2}{5}}{\frac{3}{5}} = \frac{2}{3}$.

-“상추를 사는 사람은 사이다도 구입한다”라는 규칙의 신뢰도 : $P(\text{사이다}|\text{상추}) = \frac{\frac{1}{5}}{\frac{2}{5}} = \frac{1}{2}$.

-따라서, “상추를 사는 사람은 사이다도 구입한다” 라는 규칙이 “삼겹살을 사는 사람은 상추도 구입한다”라는 규칙보다 신뢰도가 더 높다.

Association Analysis

연관성 규칙 예제 – 지지도, 신뢰도, 향상도 계산

향상도: $A \rightarrow B$ 라는 규칙이 있을 때, A는 B를 설명하기에 의미있는 사건/변수인가?

만약 B가 발생한 비율이 $P(B) = 0.9$ 라면, $P(B|A) = P(B)$.

즉, A와 B는 독립이 되어 A는 B를 설명하는데 아무런 도움을 주지 못함.

따라서, 주어진 규칙이 진짜로 의미가 있는지 알아보기 위해서는 $P(B|A)/P(B)$ 를 계산해야함

고객 번호	품목
1	삼겹살, 상추
2	삼겹살, 상추, 사이다
3	삼겹살, 깻잎
4	닭고기, 샤워 타올
5	닭고기, 콜라, 사이다

예)

“삼겹살을 사는 사람은 상추도 구입한다” 라는 규칙의 향상도 : $\frac{P(\text{상추}|\text{삼겹살})}{P(\text{상추})} = \frac{\frac{2}{5}}{\frac{2}{5}} = 1$.

향상도 = 1 : A와 B는 아무런 관계가 없음.

향상도 > 1 : A가 B의 발생 확률을 A를 고려하지 않을 경우보다 증가시킨다는 의미. 즉, A가 B의 발생을 예측하는데 유의미함.

향상도 < 1 : A가 B의 발생 확률을 A를 고려하지 않을 경우보다 감소시킨다는 의미. 즉, A가 B의 발생 감소를 예측하는데 유의미함. 일종의 음의 상관관계