

언어모델과 LLM

Hunsik Shin

Department of Industrial and Data Engineering

{hunsik.shin}@hongik.ac.kr

언어모델 (Language Model, LM)

왜 언어 모델이 필요한가?


"참 데이터사이언스 산업·데이터공학과에서 홍익대학교 수업은 재밌다."

"수업은 홍익대학교 재밌다 참 산업·데이터공학과에서 데이터사이언스"

"홍익대학교 산업·데이터공학과에서 데이터사이언스 수업은 참 재밌다"

언어모델 (Language Model, LM)

언어모델의 발전



* Bengio, Y., Ducharme, R., Vincent, P., & Jauvin, C. (2003). A neural probabilistic language model. *Journal of machine learning research*, 3(Feb), 1137-1155.

** Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in neural information processing systems*, 27..

*** Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, 30

**** Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019, June). Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)* (pp. 4171-4186).

***** Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., ... & Amodei, D. (2020). Language models are few-shot learners. *Advances in neural information processing systems*, 33, 1877-1901.

언어모델 (Language Model, LM)

기본 개념과 용어

- **임베딩 Embedding**
 - 단어(토큰)를 모델이 계산할 수 있는 연속적인 벡터 공간 표현으로 변환하는 단계
 - 의미적으로 유사한 단어들이 벡터 공간에서도 가깝게 위치하도록 학습
- **Encoder**
 - 입력 문장을 받아 각 토큰을 문맥을 반영한 표현(contextual representation) 으로 변환
 - 문장의 의미를 이해하고 요약된 상태 표현으로 압축하는 역할
- **Decoder**
 - 이전까지 생성된 토큰과 입력 정보를 바탕으로 다음 토큰을 순차적으로 생성
 - 언어모델에서는 확률적으로 가장 적절한 출력 문장을 만들어내는 생성기 역할
- **Attention**
 - 문장 내에서 어떤 토큰이 다른 토큰을 볼지 가중치를 학습하는 메커니즘
 - 거리와 상관없이 중요한 단어들에 직접 집중해 문맥 의존성을 효과적으로 모델

언어모델 (Language Model, LM)

언어모델(Language Model) 이란?

문장 또는 단어 시퀀스가 나타날 확률을 계산하는 모델

주어진 단어들의 등장 확률을 기반으로, 자연스러운 문장을 생성하거나 다음 단어를 예측하는 모델

목표: 기계에게 많은 말뭉치를 훈련시켜서 언어 모델을 통해 현실에서의 확률 분포를 근사하는 것

1. $P(w_1, w_2, \dots, w_n)$ — 문장 전체의 확률 계산
2. $P(w_n \mid w_1, \dots, w_{n-1})$ — 이전 단어들을 보고 다음 단어의 확률 예측
→ 확률을 통해 자연스러운 문장 생성 가능



<검색 엔진에서의 언어 모델이 동작하는 예 : 다음 단어 예측>

기계 번역 (Machine Translation)

- $P[\text{'나는 버스를 탔다'} \mid \text{'I took the bus'}]$ > $P[\text{'나는 버스를 탄다'} \mid \text{'I took the bus'}]$

오타-띄어쓰기 교정 (Spell & Space Correction)

- $P[\text{'아버지가 방에 들어가신다'} \mid \text{'아버지가방에들어가신다'}]$ > $P[\text{'아버지 가방에 들어가신다'} \mid \text{'아버지가방에들어가신다'}]$

언어모델 (Language Model, LM)

언어모델(Language Model) 이란?

문장 또는 단어 시퀀스가 나타날 확률을 계산하는 모델

→ 전체 말뭉치에서 문장을 구성하는 단어들이 등장한 확률을 통해 문장의 확률을 계산

$$P[\text{'나는 버스를 탔다'}] = P[\text{'나는'}, \text{'버스를'}, \text{'탔다'}]$$

Mathematical Form

문서 = 단어 시퀀스 W 가 n 개의 단어($w_i, i = 1, 2, \dots, n$)들로 구성

단어 시퀀스 W 가 등장할 확률은 아래와 같이 표현 가능

$$P(W) = P(w_1, w_2, \dots, w_n)$$

언어모델 (Language Model, LM)

Statistical Language Model(통계적 언어 모델, SLM)


Language Model은 다음과 같이 조건부 확률을 활용하여 표현 가능
단어 시퀀스 w 가 n 개의 단어($w_i, i = 1, 2, \dots, n$)들로 구성
단어 시퀀스 w 가 등장할 확률은 아래와 같이 표현 가능

$$P(W) = P(w_1, w_2, \dots, w_n)$$

$$= P(w_1) \frac{P(w_1, w_2)}{P(w_1)} \frac{P(w_1, w_2, w_3)}{P(w_1, w_2)} \dots \frac{P(w_1, w_2, w_3, \dots, w_n)}{P(w_1, w_2, w_3, \dots, w_{n-1})}$$

$$= P(w_1)P(w_2|w_1)P(w_3|w_1, w_2) \dots P(w_n|w_1, \dots, w_{n-1}) = \prod_{i=1}^n P(w_i|w_1, w_2, \dots, w_{i-1})$$

- 1) $P(\text{"학다홍 수업 터산다익업 참 교인과에 데.이서공재학는사트"})$
- 2) $P(\text{"수업은 산업 참 데이터공학과에서 홍익대학교 데이터사이언스재밌다"})$
- 3) $P(\text{"홍익대학교 산업.데이터공학과에서 데이터사이언스 수업은 참 재밌다."})$



언어모델 (Language Model, LM)

Statistical Language Model(통계적 언어 모델, SLM)

이전 단어들이 주어졌을 때, 다음 단어를 예측하는 방법 → Next Token Prediction (NTP)

주어진 단어들로부터 그 다음에 올 단어에 대한 확률을 계산 → 가장 높은 확률에 해당하는 단어 선택

예시 나는 버스를 _____ ➡ 나는 버스를 _____

 찾다
 택시
 먹다
 탔다
 ⋮

언어모델 (Language Model, LM)

Statistical Language Model(통계적 언어 모델, SLM)

이전 단어들이 주어졌을 때, 다음 단어를 예측하는 방법 → Next Token Prediction (NTP)

주어진 단어들로부터 그 다음에 올 단어에 대한 확률을 계산 → 가장 높은 확률에 해당하는 단어 선택

예시

나는 버스를 _____	→	나는 버스를 _____
찾다		$P(\text{찾다} \text{나는, 버스를}) = 0.11$
택시		$P(\text{택시} \text{나는, 버스를}) = 0.01$
먹다		$P(\text{먹다} \text{나는, 버스를}) = 0.05$
탔다		$P(\text{탔다} \text{나는, 버스를}) = 0.25$
⋮		⋮

언어모델 (Language Model, LM)

Statistical Language Model(통계적 언어 모델, SLM)

이전 단어들이 주어졌을 때, 다음 단어를 예측하는 방법 → Next Token Prediction (NTP)

주어진 단어들로부터 그 다음에 올 단어에 대한 확률을 계산 → 가장 높은 확률에 해당하는 단어 선택

예시

나는 버스를 _____	→	나는 버스를 _____
찾다		$P(\text{찾다} \text{나는, 버스를}) = 0.11$
택시		$P(\text{택시} \text{나는, 버스를}) = 0.01$
먹다		$P(\text{먹다} \text{나는, 버스를}) = 0.05$
탔다		$P(\text{탔다} \text{나는, 버스를}) = 0.25 \rightarrow \text{Maximum!}$
⋮		⋮


언어모델 (Language Model, LM)

Statistical Language Model(통계적 언어 모델, SLM)

이전 단어들이 주어졌을 때, 다음 단어를 예측하는 방법 → Next Token Prediction (NTP)

주어진 단어들로부터 그 다음에 올 단어에 대한 확률을 계산 → 가장 높은 확률에 해당하는 단어 선택

예시



언어모델 (Language Model, LM)

Statistical Language Model(통계적 언어 모델, SLM)

각각의 조건부 확률을 빈도(Count) 기반으로 부여: co-occurrence와 frequency

$$P(w_i | w_1, w_2, \dots, w_{i-1}) = \frac{\text{Count}(w_1, w_2, \dots, w_i)}{\text{Count}(w_1, w_2, \dots, w_{i-1})}$$

$\text{Count}(w_1, w_2, \dots, w_i)$: Corpus에서 $(w_1, w_2, \dots, w_i)$ 라는 단어 sequence가 나타난 수

예) 특정 말뭉치(Corpus)에서 '나는 버스를' 뒤에 '탔다'가 총 50번 등장 했고, '나는 버스를'가 100번 등장했다면?

$$\rightarrow P(\text{'탔다'} \mid \text{'나는 버스를'}) = P(\text{'나는 버스를 탔다'} \mid \text{'나는 버스를'}) = 0.5$$

언어모델 (Language Model, LM)

Statistical Language Model(통계적 언어 모델, SLM)

언어모델의 목표

기계에게 많은 말뭉치를 훈련시켜서 언어 모델을 통해 현실에서의 확률 분포를 근사하는 것
count기반으로 확률을 잘 부여하려면 매우 방대한 양의 말뭉치가 필요

예시) 학습한 Corpus에 '나는 버스를 탔다'라는 문장이 없으면, 이 확률은 0이 됨

충분하지 않은 말뭉치로 인한 낮은 확률에 해당하는 문장이 잘못된 문장은 아닐 수 있음

Sparsity Problem (희소 문제)

충분한 데이터를 관측하지 못하여 언어를 정확히 모델링하지 못하는 문제

완화하는 방법으로 n-gram language 모델이 활용됨

언어모델 (Language Model, LM)

Statistical Language Model(통계적 언어 모델, SLM)

Sparsity Problem (희소 문제)

충분한 데이터를 관측하지 못하여 언어를 정확히 모델링하지 못하는 문제
완화하는 방법으로 n-gram language 모델이 활용됨

– 다음과 같은 문장을 생각해봅시다.

- 아래 문장에서 빈칸에 들어갈 단어를 언어 모델로 예측하려고 한다.

오타니쇼헤이는 일본 국적의 투타 겸업을 하는 야구선수로, 2021년 아메리칸리그 MVP를 _____

- 아래 조건부 확률 값이 가장 큰 w 를 선택하면 된다.

$$P(w|\text{오타니쇼헤이는, 일본, 국적의, ..., MVP를}) = \frac{P(\text{오타니쇼헤이는, 일본, 국적의, ..., MVP를, } w)}{P(\text{오타니쇼헤이는, 일본, 국적의, ..., MVP를})}$$

언어모델 (Language Model, LM)

Statistical Language Model(통계적 언어 모델, SLM)

Sparsity Problem (희소 문제)

충분한 데이터를 관측하지 못하여 언어를 정확히 모델링하지 못하는 문제
완화하는 방법으로 n-gram language 모델이 활용됨

- 다음과 같은 문장을 생각해봅시다.

- 아래 문장에서 빈칸에 들어갈 단어를 언어 모델로 예측하려고 한다.

오타니쇼헤이는 일본 국적의 투타 겸업을 하는 야구선수로, 2021년 아메리칸리그 MVP를 _____

- 아래 조건부 확률 값이 가장 큰 w 를 선택하면 된다.

$$P(w|\text{오타니쇼헤이는, 일본, 국적의, ..., MVP를}) = \frac{P(\text{오타니쇼헤이는, 일본, 국적의, ..., MVP를, } w)}{P(\text{오타니쇼헤이는, 일본, 국적의, ..., MVP를})}$$

Corpus에서 이 정도로 긴 단어 sequence가 존재할 확률은 0에 가까울 것

→ 이런 모델링 자체가 어렵다.

→ 전체 단어 sequence를 보지 말고, 몇 개의 단어만 보면 어떨까?

언어모델 (Language Model, LM)

Statistical Language Model(통계적 언어 모델, SLM)

Sparsity Problem (희소 문제)

충분한 데이터를 관측하지 못하여 언어를 정확히 모델링하지 못하는 문제
완화하는 방법으로 n-gram language 모델이 활용됨

- 다음과 같은 문장을 생각해봅시다.

- 아래 문장에서 빈칸에 들어갈 단어를 언어 모델로 예측하려고 한다.

오타니쇼헤이는 일본 국적의 투타 겸업을 하는 야구선수로, 2021년 아메리칸리그 MVP를 _____

- 앞의 1개 단어만 본다면,

$$P(w|MVP를) = \frac{P(MVP를, w)}{P(MVP를)}$$

- 앞의 2개 단어만 본다면,

$$P(w|아메리칸리그, MVP를) = \frac{P(아메리칸리그, MVP를, w)}{P(아메리칸리그, MVP를)}$$

Corpus에서 이런 단어 sequence가 나올 확률은 이전보다 높을 것!

언어모델 (Language Model, LM)

Statistical Language Model(통계적 언어 모델, SLM)

Sparsity Problem (희소 문제)

충분한 데이터를 관측하지 못하여 언어를 정확히 모델링하지 못하는 문제
완화하는 방법으로 n-gram language 모델이 활용됨

- **n-gram**

- n개의 연속적인 단어 나열 (n은 사용자가 정하는 값)
- 이전 단어들이 주어졌을 때, 다음 단어의 등장 확률은 앞의 n-1개의 단어에만 dependent

Statistical LM	$P(W) = \prod_{i=1}^N P(w_i w_1, w_2, \dots, w_{i-1})$
n-gram LM	$P(W) = \prod_{i=1}^N P(w_i w_{i-(n-1)}, w_{i-(n-2)}, \dots, w_{i-1})$

언어모델 (Language Model, LM)

Statistical Language Model(통계적 언어 모델, SLM)

Sparsity Problem (희소 문제)

충분한 데이터를 관측하지 못하여 언어를 정확히 모델링하지 못하는 문제
완화하는 방법으로 n-gram language 모델이 활용됨

- **n-gram의 한계**

- How to select n?

- **Small n**

- 희소성 문제 완화: Corpus에서 단어 sequence가 있을 확률은 높아짐
 - 장기 의존성 문제 심화: 문장의 전체 문맥을 고려하지 않은 채 token 선택

- **Large n**

- 희소성 문제 심화: Corpus에서 단어 sequence가 있을 확률이 낮아짐
 - 장기 의존성 문제 완화: 문장의 전체 문맥을 고려하여 token 선택

- n은 최대 5를 넘지 않도록 권장됨
 - 또한, 다양한 n을 섞어서 사용하기도 함

An adorable little boy is spreading _____

Small n: 짧은 단어 sequence가 있을 확률은 높으나, 문맥에 맞지 않게 선택 ex) insults

Large n: 긴 단어 sequence가 있을 확률은 낮으나, 존재한다면 문맥에 맞게 선택 ex) smiles

언어모델 (Language Model, LM)

Statistical Language Model(통계적 언어 모델, SLM)

Sparsity Problem (희소 문제)

충분한 데이터를 관측하지 못하여 언어를 정확히 모델링하지 못하는 문제
완화하는 방법으로 n-gram language 모델이 활용됨

- 이런 기법에도 sparsity problem은 완전히 해결되지 않음
 - NNLM의 등장: Sparsity problem을 Word Embedding으로 해결

Word Embedding을 사용하면 단어 벡터 간 유사도를 얻을 수 있다.

귀여운 $\approx$ 사랑스러운

강아지 $\approx$ 고양이

좋아해 $\approx$ 사랑해

이로부터 훈련 데이터에 없던 시퀀스라도 생성이 가능.


훈련 데이터: 귀여운 강아지 좋아해 $\longrightarrow$ 사랑스러운 고양이 사랑해 (훈련 데이터에 없던 시퀀스)

언어모델 (Language Model, LM)

Neural Network Language Model(NNLM)

배경

- 당시 주류였던 N-gram 모델 (통계적 언어 모델) 은 단어의 빈도수를 기반으로 확률을 계산
→ 학습 데이터에 없는 단어 조합이 나오면 확률이 0이 되는 '희소 문제(Sparsity Problem)'가 발생
- N-gram은 '강아지'와 '개'가 의미적으로 유사하다는 것을 알지 못하고 완전히 다른 단어로 취급
단어 유사성 고려 X)




언어모델 (Language Model, LM)



Neural Network Language Model(NNLM)

• 핵심 아이디어

- 신경망을 통한 확률 예측: 이전 단어들의 벡터를 신경망의 입력으로 넣어, 다음에 올 단어의 확률을 계산
- 단어의 분산 표현 (Distributed Representation): 단어를 단순히 숫자로 세는 것이 아니라, 다차원 공간상의 밀집 벡터 (Dense Vector)로 표현. → 의미가 비슷한 단어들은 벡터 공간에서 가까이 위치 (현재의 Word Embedding 모태)




" A young girl plays with _? _ " → [Language Model] → "dog"
Neural Network를 통한 확률 예측 예시



* <https://suriyadeepan.github.io/>

언어모델 (Language Model, LM)

Neural Network Language Model(NNLM)






모델 구조

- 1. Input Layer:** 예측하려는 단어($word_t$) 앞의 $n-1$ 개 단어들($(word_{t-1}, \dots, word_{t-n+1})$) 을 입력
- 2. Projection Layer (C):** 각 단어를 미리 정의된 크기(m 차원)의 벡터로 변환(Look-up table을 이용한 Embedding)
→ 모든 단어는 동일한 행렬 C 를 공유하여 벡터화
- 3. Hidden Layer:** 변환된 벡터들을 하나로 이어 붙여(Concatenate) 비선형 활성화 함수(주로 $\tanh$)를 통과
→ 단어 간의 복잡한 관계(=비선형 관계)를 학습
- 4. Output Layer:** Softmax 함수를 사용하여 전체 단어 집합(Vocabulary) 중 어떤 단어가 올지 확률 분포로 출력

언어모델 (Language Model, LM)

Neural Network Language Model(NNLM)



" A young girl plays with __?" → [Language Model] → "dog"


언어모델 (Language Model, LM)

Distributed Representation – Word2Vec (Mikolov et al., 2013)

Distributed Representation은 의미적으로 유사한 단어가 벡터 공간에서 가까운 위치에 놓이도록 학습하는 방법

2 Learning model – prediction of target word

Doc1 : { 'You are a very good boy.' 'You are a good girl too.' }




언어모델 (Language Model, LM)

Distributed Representation – Word2Vec (Mikolov et al., 2013)

Distributed Representation은 의미적으로 유사한 단어가 벡터 공간에서 가까운 위치에 놓이도록 학습하는 방법

2 Learning model – prediction of target word

Doc1 : { ' You are a very good boy.' 'You are a good girl too.' }




언어모델 (Language Model, LM)

Distributed Representation – Word2Vec (Mikolov et al., 2013)

Distributed Representation은 의미적으로 유사한 단어가 벡터 공간에서 가까운 위치에 놓이도록 학습하는 방법

2 Learning model – prediction of target word

Doc1 : { ' You are a very good boy.' 'You are a good girl too.' }




언어모델 (Language Model, LM)

Distributed Representation – Word2Vec (Mikolov et al., 2013)

Distributed Representation은 의미적으로 유사한 단어가 벡터 공간에서 가까운 위치에 놓이도록 학습하는 방법

2 Learning model – prediction of target word

Doc1 : { ' You are a very good boy ' 'You are a good girl too. ' }




언어모델 (Language Model, LM)

Distributed Representation – Word2Vec (Mikolov et al., 2013)

Distributed Representation은 의미적으로 유사한 단어가 벡터 공간에서 가까운 위치에 놓이도록 학습하는 방법

2 Learning model – prediction of target word

Doc1 : { ' You are a very good boy.' 'You are a good girl too.' }




언어모델 (Language Model, LM)

Distributed Representation – Word2Vec (Mikolov et al., 2013)

Distributed Representation은 의미적으로 유사한 단어가 벡터 공간에서 가까운 위치에 놓이도록 학습하는 방법

2 Learning model – prediction of target word

Doc1 : { ' You are a very good boy.' ' You are a good girl too. ' }




언어모델 (Language Model, LM)

Distributed Representation – Word2Vec (Mikolov et al., 2013)

Distributed Representation은 의미적으로 유사한 단어가 벡터 공간에서 가까운 위치에 놓이도록 학습하는 방법

2 Learning model – prediction of target word

Doc1 : { ' You are a very good boy.' ' You are a good girl too.' }




언어모델 (Language Model, LM)

Distributed Representation – Word2Vec (Mikolov et al., 2013)

Distributed Representation은 의미적으로 유사한 단어가 벡터 공간에서 가까운 위치에 놓이도록 학습하는 방법

2 Learning model – prediction of target word

Doc1 : { ' You are a very good boy.' ' You are a good girl too.' }




언어모델 (Language Model, LM)

Recurrent Neural Network

언어 모델은 문장 내에서 단어의 순서에 확률을 할당하는 모델

→ 이전까지 등장한 단어들($w_1, w_2, \dots, w_{t-1}$)이 주어졌을 때, 다음에 올 단어 w_t 예측




배경

전통적인 통계적 언어 모델(N-gram)이나 일반적인 Feed-forward 신경망은 고정된 길이의 입력만 처리할 수 있다는 한계
문장은 길이가 제각각 다른 경우 처리할 수 있는 방안 필요

모델 : $h_t = \tanh(W_{hh}h_{t-1}W_{hx}x_t + b_h)$

- x_t : 현재 시점의 단어 벡터 (Embedding)
- h_{t-1} : 이전 시점까지의 맥락을 담고 있는 은닉 상태 (Hidden State)
- W : 학습해야 할 가중치 매개변수
- h_t : 현재까지의 정보를 업데이트한 새로운 은닉 상태



<RNN 구조>

언어모델 (Language Model, LM)

Recurrent Neural Network

A RNN Language Model

output distribution

$$\hat{y} = \text{softmax}(W_2 h^{(t)})$$



hidden states

$$h^{(t)} = f(W_h h^{(t-1)} + W_e c_t)$$

$h^{(0)}$ is initial hidden state!

word embeddings

c_1, c_2, c_3, c_4



언어모델 (Language Model, LM)

Long Short-Term Memory



배경

RNN 모델의 장기 의존성 문제를 해결하기 위해 등장

Cell State'라는 통로를 추가하여, 어떤 정보를 장기적으로 유지할지(Forget gate, Input gate) 정교하게 제어

- Gate의 역할

- forget gate : 과거 정보를 얼마나 유지할 것인지?
- input gate : 새로 입력된 정보는 얼마만큼 활용할 것인지?
- output gate : 두 정보를 계산하여 나온 출력 정보를 얼마만큼 넘겨줄 것인지?
- cell-state: 역전파 과정에서 활성화 함수를 거치지 않아 정보 손실이 없기 때문에 뒷 쪽 시퀀스와 앞쪽 시퀀스의 정보를 모두 가지고 있음



언어모델 (Language Model, LM)

- **Sequence to Sequence Model (Seq2Seq)**

- 길이가 다른 입력 시퀀스를 받아, 또 다른 시퀀스를 출력하는 모델 구조



- **Encoder**

입력 문장을 한 단어씩 순서대로 읽음

- 보통 RNN / LSTM 사용
- 마지막 hidden state가 입력 전체의 요약
→ 요약 벡터를 Context Vector라고 부름

- **Decoder (출력 생성)**




- Context Vector를 받아서 단어를 하나씩 생성
- 이전에 생성한 단어를 다시 입력으로 사용



언어모델 (Language Model, LM)

Transformer

- 인코더에서 입력 시퀀스를 입력받고, 디코더에서 출력 시퀀스를 출력
- 인코더와 디코더라는 단위가 N개로 구성되는 구조
- 트랜스포머를 제안한 논문에서는 인코더와 디코더의 개수를 각각 6개 사용
#멀티 헤드 어텐션, #셀프 어텐션



* <https://wikidocs.net/31379>



언어모델 (Language Model, LM)

Generative Pre-trained Transformer, GPT

- 트랜스포머의 디코더(Decoder) 구조를 사용
- 문장을 한 방향(Unidirectional)으로 읽으며 다음에 올 단어를 예측

학습 방식

- 이전 단어들을 보고 다음 단어를 생성하는 'Causal Language Modeling' 방식
- 문장의 흐름이 자연스럽고 창의적인 텍스트를 생성하는 능력이 좋음



	GPT-1	GPT-2	GPT-3	GPT-3.5	GPT-4 Models
파라미터 개수	1억 1700만개	15억	1,750억	?	1조 8천억(추정)
디코더의 층	12	48	96	?	?
처리 가능한 토큰 개수	512	1024	2048	?	128,000
은닉층의 크기	768	1600	12288	?	?

대형언어모델 (Large Language Model, LLM)

Large Language Model

- LLM은 Transformer 계열(특히 self-attention)을 기반으로, 방대한 텍스트(및 경우에 따라 코드·이미지·표 등)를 이용해 대규모 사전학습(pre-training)을 수행
- 언어를 넘어 다양한 작업을 수행할 수 있는 범용 기반 모델(foundation model)로서 동작
- Transformer 구조를 사용하여 긴 거리 의존성에 강할 뿐 아니라 GPU에서 병렬 처리가 쉬워, 모델 파라미터 수·데이터 규모·연산량을 함께 키우는 스케일업이 가능

대형언어모델 (Large Language Model, LLM)

Large Language Model

Instruction Tuning

- LLM이 문장을 생성하는 모델에서 "지시를 이해하고 수행하는 모델"로 바뀌는 핵심 학습 단계
- 기존 언어모델처럼 여전히 next-token prediction 방식으로 학습되지만, 예측 대상은 "다음에 자연스럽게 나올 문장"이 아니라 "주어진 지시에 대해 사람이 실제로 쓸 법한 응답"으로 목적이 달라짐

예) 기존 언어 모델

Input: "Translate the following sentence into ____"

Output: "Korean"

LLM – instruction tuning

Instruction: Translate the following sentence into Korean.

Input: Machine learning improves decision making.

Response: 머신러닝은 의사결정을 향상시킨다.

대형언어모델 (Large Language Model, LLM)

APPLICATIONS

LLM 응용 분야

산업 전반을 혁신하는 다양한 활용 사례



고객지원 & 챗봇

- 24/7 무중단 자동 응대 시스템
- 평균 처리 시간(AHT) 획기적 단축
- 감정 분석 기반의 맞춤형 대응



콘텐츠 생성

- 마케팅 카피 및 광고 문구 작성
- 블로그, 뉴스레터 초안 자동 생성
- 개인화된 이메일 및 메시지 발송



코드 & 개발

- 지능형 코드 자동 완성 (Copilot)
- 코드 리팩토링 및 주석 자동화
- 버그 탐지 및 테스트 케이스 생성



검색 & RAG

- 사내 지식 베이스 기반 질의응답
- 방대한 문서 요약 및 핵심 추출
- 최신 정보와 연동된 정확한 답변



데이터 분석

- 자연어 질의를 SQL 쿼리로 변환
- 데이터 인사이트 자동 추출 및 시각화
- 비즈니스 리포트 생성 자동화



산업 특화

- 의료: 임상 기록 요약 및 진단 보조
- 법률: 계약서 검토 및 판례 분석
- 금융: 시장 리포트 분석 및 리스크 탐지